AMAZON EMR

CONTENIDO

AMAZON EMR 2
Amazon EMR sin servidor 2
FUNCIONAMIENTO DE AMAZON EMR 2
CARACTERÍSTICAS DE AMAZON EMR 3
VENTAJAS DE AMAZON EMR 7
CASOS DE USO DE AMAZON EMR 9

AMAZON EMR

Amazon EMR, anteriormente denominada Amazon Elastic MapReduce, es una plataforma de clústeres gestionada que simplifica la ejecución de marcos de big data, como Apache Hadoop y Apache Spark, para procesar y analizar grandes cantidades de datos. Mediante el uso de estos marcos de trabajo y proyectos de código abierto relacionados, puede procesar datos para fines de análisis y cargas de trabajo de inteligencia empresarial. Además, Amazon EMR le permite transformar y trasladar grandes cantidades de datos hacia y desde otros almacenes de datos y bases de datos de AWS, tales como Amazon Simple Storage Service (Amazon S3) y Amazon DynamoDB.

Amazon EMR simplifica la creación y la operación de entornos y aplicaciones de macrodatos. Las características relacionadas con EMR incluyen un aprovisionamiento fácil, escalado gestionado, reconfiguración de clústeres y EMR Studio para el desarrollo colaborativo.

Con EMR puede ejecutar análisis a escala de petabytes a menos de la mitad del costo de las soluciones tradicionales en las instalaciones y con una velocidad 1,7 veces superior que Apache Spark estándar.

Amazon EMR sin servidor

Amazon EMR Serverless es una opción sin servidor en Amazon EMR que facilita a los analistas de datos e ingenieros la ejecución de marcos de análisis de big data de código abierto sin necesidad de configurar, administrar y escalar clústeres o servidores. Obtendrá todas las características y beneficios de Amazon EMR sin necesidad de que los expertos planifiquen y administren clústeres.

FUNCIONAMIENTO DE AMAZON EMR

Amazon EMR es la solución de macrodatos en la nube líder del sector destinada al procesamiento de datos a escala de petabytes, análisis interactivo y aprendizaje automático mediante el uso de marcos de código abierto, como Apache Spark, Apache Hive y Presto.

Amazon EMR es una plataforma de clúster administrada que le permite procesar y analizar los datos de su lago de datos.
A diferencia de las limitaciones de infraestructura de los clústeres on-premise, EMR desacopla la informática y el almacenamiento, ofreciéndole la posibilidad de escalar cada uno de forma independiente utilizando S3 como capa de almacenamiento.
Amazon EMR es magnífico para procesar datos por lotes, porque le permite procesar cantidades masivas de datos de forma eficiente y es probable que trabaje
con cantidades masivas de datos en su lago de datos.
Con EMR, puede crear clústeres de larga duración o transitorios. La ventaja de un clúster transitorio es que puede poner en marcha un clúster y luego se apaga cuando finaliza su trabajo de procesamiento, pagando sólo por lo que utiliza. Por el contrario, los clústeres persistentes siguen funcionando una vez finalizado el procesamiento de los datos. Si determina que su clúster estará inactivo la mayor parte del tiempo, es mejor utilizar clústeres transitorios. Por ejemplo, si tiene un trabajo de procesamiento por lotes que extrae sus registros web de Amazon S3 y procesa los datos una vez por hora, probablemente será más rentable utilizar clústeres transitorios para procesar sus datos y luego apagar los nodos cuando el procesamiento haya finalizado.

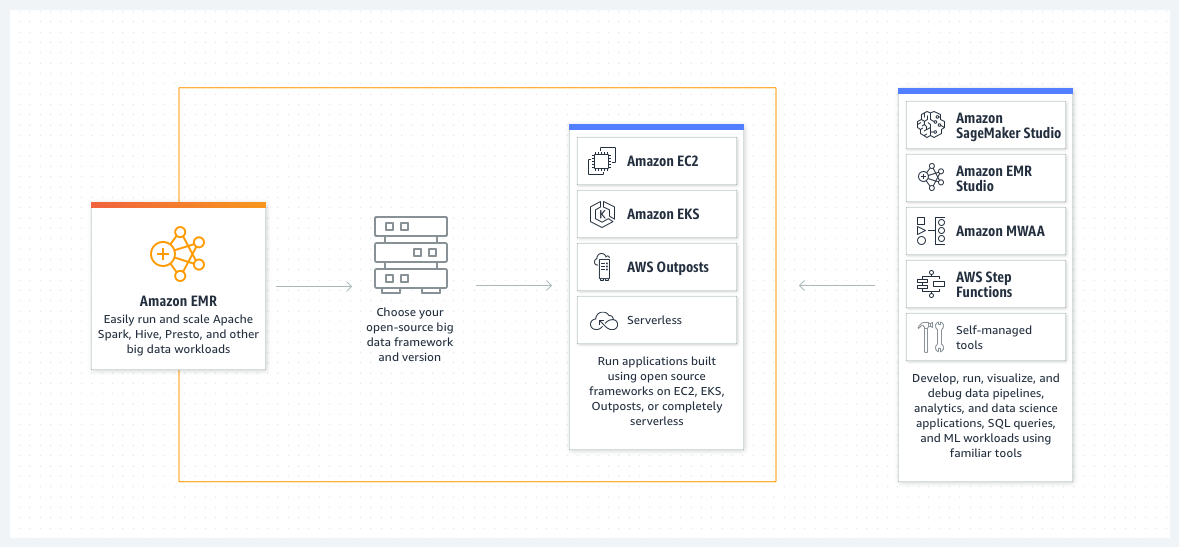

CARACTERÍSTICAS DE AMAZON EMR

1. FACILIDAD DE USO: Amazon EMR simplifica la creación y la operación de entornos y aplicaciones de big data. Las características relacionadas con EMR incluyen un aprovisionamiento fácil, escalado gestionado, reconfiguración de clústeres y EMR Studio para el desarrollo colaborativo.

Aprovisione clústeres en minutos: Puede lanzar un clúster de EMR en cuestión de minutos. No hay que preocuparse por el aprovisionamiento de infraestructura, la disposición del clúster, la configuración ni el ajuste. EMR se encarga de estas tareas, lo que permite centrar a sus equipos en desarrollar aplicaciones de big data diferenciadas.

Escale recursos fácilmente para satisfacer las necesidades de la empresa: Puede establecer fácilmente políticas de escalado administradas de EMR ascendentes o descendentes y permitir que su clúster de EMR administre automáticamente los recursos informáticos para satisfacer sus necesidades de uso y rendimiento. De esta manera, se mejora la utilización de los clústeres y se ahorra en costes.

Escalado administrado por EMR: Redimensiona el clúster de forma automática para obtener un mejor rendimiento al menor coste posible. Con el escalado administrado por EMR puede especificar los límites informáticos máximos y mínimos para sus clústeres y Amazon EMR los redimensiona automáticamente para el mejor rendimiento y uso de recursos. El escalado administrado por EMR prueba continuamente métricas claves asociadas con las cargas de trabajo que se ejecutan en clústeres.

2. ELASTICIDAD: Amazon EMR le permite aprovisionar con rapidez y facilidad toda la capacidad que necesite, y agregarla o eliminarla de forma automática o manual. Es muy útil si cuenta con requisitos de procesamiento impredecibles o variables. Por ejemplo, si la mayor parte del procesamiento se produce por la noche, es posible que necesite 100 instancias durante el día y 500 por la noche. También puede suceder que necesite una gran capacidad durante un breve período de tiempo. Con Amazon EMR, puede aprovisionar rápidamente cientos o miles de instancias, realizar ajustes de escala de manera automática para satisfacer los requisitos de capacidad de cómputo y eliminar el clúster cuando se complete el trabajo (para evitar pagar por capacidad inactiva).

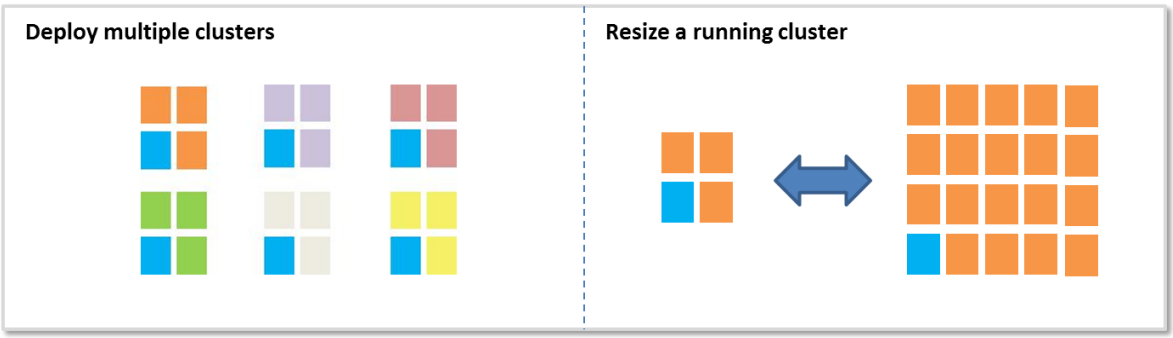

Existen dos opciones principales para añadir o eliminar capacidad:

Implementar varios clústeres: Si necesita más capacidad, puede lanzar fácilmente un nuevo clúster y finalizarlo cuando ya no lo necesite. No existe ningún límite en cuanto al número de clústeres que puede tener. Es posible que quiera utilizar varios clústeres si tiene varios usuarios o aplicaciones. Por ejemplo, puede almacenar los datos de entrada en Amazon S3 y lanzar un clúster por cada aplicación que necesite procesar los datos. Se puede optimizar un clúster para CPU, otro para almacenamiento, etc.

Redimensionar un clúster en ejecución: Con Amazon EMR, es fácil de usar Escalado administrado por EMR, escalar automáticamente o redimensionar manualmente un clúster en ejecución. Quizás desee ampliar un clúster para añadir más potencia de procesamiento de forma temporal o reducir el clúster para ahorrar costes cuando tenga capacidad inactiva. Por ejemplo, algunos clientes agregan cientos de instancias a sus clústeres cuando se produce el procesamiento por lotes y eliminan las instancias adicionales cuando se completa el procesamiento. Al agregar instancias al clúster, EMR puede empezar a utilizar la capacidad aprovisionada en cuanto esté disponible. Cuando reduzca la escala, EMR elegirá de manera proactiva nodos inactivos para reducir el impacto en los trabajos en ejecución.

3. BAJO COSTO: Amazon EMR está diseñado para reducir el costo de procesamiento de grandes volúmenes de datos. Algunas de las características que permiten que tenga un coste reducido son los precios por segundo, la integración con las instancias de spot de Amazon EC2, la integración con las instancias reservadas de Amazon EC2, la elasticidad y la integración con Amazon S3.

Precios bajos por segundo: los precios de Amazon EMR se aplican por segundo con un mínimo de un minuto y comienzan con 0,015 USD por hora de instancia en el caso de las instancias pequeñas (131,40 USD al año).

4. ALMACENES DE DATOS FLEXIBLES: Con Amazon EMR puede utilizar varios almacenes de datos, incluidos Amazon S3, Hadoop Distributed File System (HDFS) y Amazon DynamoDB.

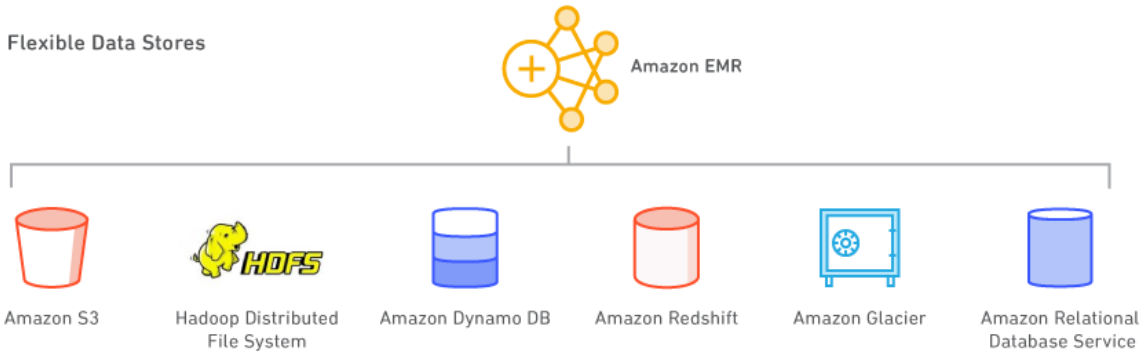

5. USE SUS APLICACIONES DE CÓDIGO ABIERTO FAVORITAS: Mediante los lanzamientos con control de versiones en Amazon EMR, puede seleccionar y usar fácilmente los últimos proyectos de código abierto en su clúster de EMR, incluidas las aplicaciones presentes en los ecosistemas Apache Hadoop y Spark. Amazon EMR se encarga de instalar y configurar el software, para que pueda dedicar más tiempo a aumentar el valor de sus datos sin preocuparse por tareas administrativas y de infraestructura.

6. HERRAMIENTAS DE BIG DATA: Amazon EMR es compatible con herramientas eficientes y probadas de Hadoop, como Apache Spark, Apache Hive, Presto y Apache HBase. Los científicos de datos utilizan EMR para ejecutar herramientas de aprendizaje profundo y aprendizaje automático como TensorFlow, Apache MXNet y, mediante procesos de arranque, añaden herramientas y bibliotecas específicas de casos de uso. Los analistas de datos utilizan EMR Studio, Hue y EMR Notebooks para el desarrollo interactivo y para crear trabajos de Apache Spark y enviar consultas de SQL a Apache Hive y Presto. Los ingenieros de datos utilizan EMR para el desarrollo de la canalización y el procesamiento de datos, y utilizan Apache Hudi para simplificar la administración de datos de crecimiento gradual y los casos de uso de privacidad de datos que requieren operaciones de inserción, actualización y eliminación de nivel de registro.

VENTAJAS DE AMAZON EMR

El uso de Amazon EMR conlleva muchos beneficios, vamos a ver algunos de forma general: sobre estos beneficios y enlaces a información adicional que le ayudan a seguir explorando.

- **Ahorro de costos**: Los precios de Amazon EMR dependen del tipo de instancia y del número de instancias de Amazon EC2 que implemente y de la región en la que lance el clúster. Los precios bajo demanda ofrecen tarifas reducidas, pero puede reducir aún más el costo mediante la adquisición de instancias reservadas o instancias de spot. Las instancias de spot pueden ofrecer ahorros significativos. En algunos casos, de solo una décima parte de los precios bajo demanda.

- **Integración AWS**: Amazon EMR se integra con otros AWS servicios para proporcionar capacidades y funcionalidades relacionadas con las redes, el almacenamiento, la seguridad, etc., para su clúster. La siguiente lista proporciona diversos ejemplos de esta integración:

  - Amazon EC2 para las instancias que componen los nodos del clúster
  - Amazon Virtual Private Cloud (Amazon VPC) para configurar la red virtual en la que lanzar sus instancias
  - Amazon S3 para almacenar los datos de entrada y de salida
  - Amazon supervisará CloudWatch el rendimiento de los clústeres y configurará las alarmas
  - AWS Identity and Access Management (IAM) para configurar los permisos
  - AWS CloudTrail para auditar las solicitudes realizadas al servicio
  - AWS Data Pipeline para programar e iniciar sus clústeres
  - AWS Lake Formation para descubrir, catalogar y proteger los datos en un lago de datos de Amazon S3

- **Implementación**: El clúster de EMR consta de instancias EC2, que realizan el trabajo que envía a su clúster. Al lanzar el clúster, Amazon EMR configura las instancias con las aplicaciones que elija, como Apache Hadoop o Spark. Elija el tamaño y el tipo de instancia que mejor se adapte a las necesidades de procesamiento de su clúster: procesamiento por lotes, consultas de baja latencia, streaming de datos o almacenamiento de datos de gran tamaño.

  Amazon EMR ofrece distintas formas de configurar el software en su clúster. Por ejemplo, puede instalar una versión de Amazon EMR con un conjunto seleccionado de aplicaciones que puede incluir marcos de trabajo versátiles como, por ejemplo,

Hadoop y aplicaciones como Hive, Pig o Spark. También puede instalar una de las diversas distribuciones de MapR. Amazon EMR utiliza Amazon Linux, por lo que también puede instalar software en su clúster de forma manual o mediante el administrador de paquetes yum o desde el origen.

- **Escalabilidad y flexibilidad**: Amazon EMR proporciona flexibilidad para aumentar o reducir el escalado del clúster a medida que cambien sus necesidades informáticas. Puede cambiar el tamaño del clúster para añadir instancias durante los picos de cargas de trabajo y eliminar instancias para controlar los costos cuando desaparezcan los picos de cargas de trabajo.

  Amazon EMR también ofrece la opción de ejecutar varios grupos de instancias, para que puede utilizar instancias bajo demanda en un grupo para garantizar la potencia de procesamiento junto con las instancias de spot en otro grupo para completar los trabajos con mayor rapidez y para reducir costos. También puede combinar diversos tipos de instancias para aprovechar mejor los precios de un tipo de instancia de spot sobre otros.

  Además, Amazon EMR proporciona la flexibilidad necesaria para utilizar diversos sistemas de archivos para sus datos de entrada, de salida e intermedios. Por ejemplo, podría elegir el Sistema de archivos distribuido de Hadoop (HDFS), que se ejecuta en los nodos principal y secundarios del clúster para el procesamiento de datos que no es necesario almacenar más allá del ciclo de vida del clúster. Podría elegir el sistema de archivos de EMR (EMRFS) para utilizar Amazon S3 como capa de datos para aplicaciones que se ejecutan en su clúster para que pueda separar la computación y el almacenamiento, así como para conservar los datos cuando finaliza el ciclo de vida de su clúster. EMRFS ofrece el beneficio añadido de permitirle aumentar o reducir el escalado de sus necesidades de computación y almacenamiento de manera independiente. Para escalar sus necesidades de computación, puede cambiar el tamaño de su clúster y puede escalar sus necesidades de almacenamiento mediante el uso de Amazon S3.

- **Fiabilidad**: Amazon EMR supervisa los nodos del clúster y termina y sustituye automáticamente una instancia en caso de que se produzca algún error.

  Amazon EMR proporciona opciones de configuración que controlan cómo se termina el clúster: de forma automática o manual. Si configura el clúster para terminarlo de forma automática, se termina después de que se completen todos los pasos. Esto se conoce como clúster transitorio. Sin embargo, puede configurar el clúster para que se siga ejecutando una vez completado el procesamiento, para que pueda elegir terminarlo manualmente cuando ya no lo necesite. O bien, puede crear un clúster, interactuar con las aplicaciones instaladas directamente y, a

continuación, terminar el clúster manualmente cuando deje de necesitarlo. Los clústeres de estos ejemplos se denominan clústeres de ejecución prolongada.

Además, puede configurar la protección de terminación para evitar que las instancias del clúster se terminen por errores o problemas durante el procesamiento. Cuando se habilita la protección de terminación, puede recuperar los datos desde instancias antes de la terminación. La configuración predeterminada de estas opciones varía en función de si lanza el clúster a través de la consola, la CLI o la API.

- **Seguridad**: Amazon EMR aprovecha otros AWS servicios, como IAM y Amazon VPC, y funciones como los pares de claves de Amazon EC2, para ayudarlo a proteger sus clústeres y datos.

- **Supervisión**: Puede utilizar las interfaces de administración de Amazon EMR y los archivos de registro para solucionar problemas de clúster como, por ejemplo, averías o errores. Amazon EMR ofrece la posibilidad de archivar los archivos de registro en Amazon S3 para que pueda almacenar registros y cuestiones de solución de problemas incluso después de que el clúster termine. Amazon EMR también proporciona una herramienta de depuración opcional en la consola de Amazon EMR para examinar los archivos de registro basada en pasos, trabajos y tareas.

  Amazon EMR se integra con el fin de CloudWatch realizar un seguimiento de las métricas de rendimiento del clúster y de los trabajos dentro del clúster. Puede configurar alarmas basadas en diversas métricas como, por ejemplo, si el clúster está inactivo o el porcentaje de almacenamiento utilizado.

- **Interfaces de administración**: Existen varias formas en las que puede interactuar con Amazon EMR: Consola, AWS Command Line Interface (AWS CLI), Kit de desarrollo de software (SDK) y API de servicios web.

CASOS DE USO DE AMAZON EMR

Amazon Redshift es una poderosa herramienta que se adapta a diversos casos de uso. Algunos ejemplos incluyen:

1. **Ejecución de análisis de big data:** Ejecute procesamientos de datos a gran escala y análisis hipotéticos utilizando algoritmos estadísticos y modelos predictivos para

descubrir patrones ocultos, correlaciones, tendencias del mercado y preferencias de los clientes.

2. **Creación de canalizaciones de datos escalables:** Extraiga datos de una variedad de orígenes, procéselos a escala y póngalos a disposición de las aplicaciones y los usuarios.

3. **Procesamiento de flujos de datos en tiempo real:** Analice los eventos de orígenes de datos de streaming en tiempo real para crear canalizaciones de datos de streaming de larga duración, altamente disponibles y tolerantes a errores.

4. **Acelere la adopción de machine learning y ciencia de datos:** Analice los datos con marcos de ML de código abierto como Apache Spark MLlib, TensorFlow y Apache MXNet. Conéctese a Amazon SageMaker Studio para la formación de modelos a gran escala, el análisis y la creación de informes.