LABORATORIO DE AMAZON REDSHIFT

Este laboratorio proporciona una serie de ejercicios que ayudan a los estudiantes a comenzar a usar el servicio Amazon Redshift, una solución de almacenamiento de datos rápida, completamente administrada y a escala de petabytes que utiliza el almacenamiento en columnas para minimizar las E/S, proporciona altas tasas de compresión de datos y ofrece un rendimiento rápido.

Además, este taller ayuda a demostrar las numerosas funciones integradas en la plataforma.

El siguiente diagrama muestra las características clave con las que trabajaremos y cómo se utilizan en el entorno típico de almacenamiento de datos:

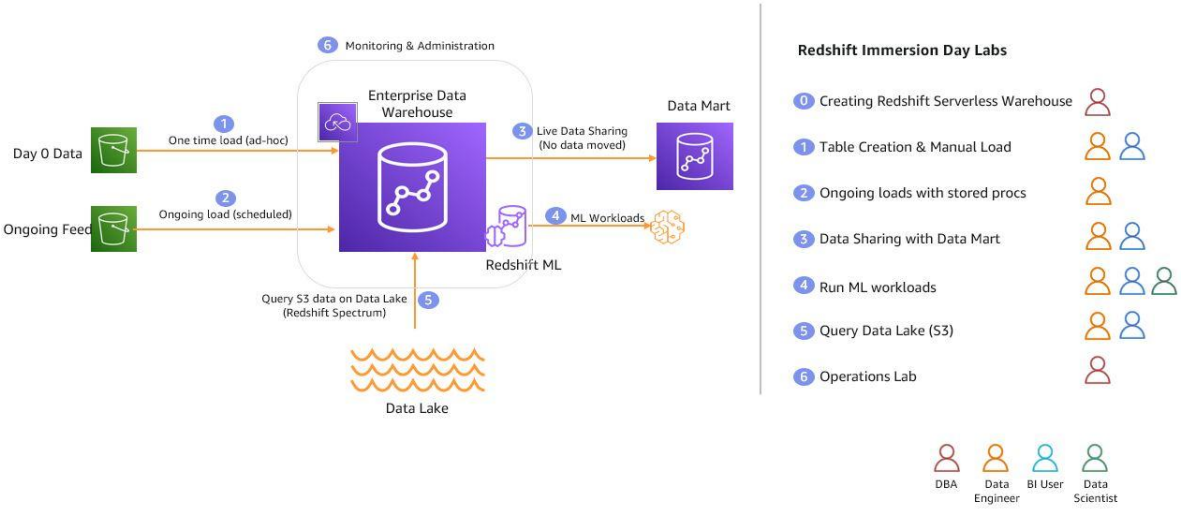

Si lo desea, puede seguir el paso a paso de este laboratorio desde la URL de AWS: https://catalog.us-east-1.prod.workshops.aws/workshops/9f29cdba-66c0-445e-8cbb-28a092cb5ba7/en-US/lab1

1. Utilizar la siguiente plantilla de CloudFormation para lanzar los recursos necesarios en su cuenta de AWS:

   https://console.aws.amazon.com/cloudformation/home?#/stacks/new?stackName=RedshiftImmersionLab&templateURL=https://s3-us-west-2.amazonaws.com/redshift-immersionday-labs/immersionserverless.yaml

El servicio ***AWS CloudFormation*** se verá a detalle en el siguiente módulo, por el momento debe saber que éste es un servicio que le ayuda a modelar y configurar sus recursos de AWS, por lo que podrá dedicar menos tiempo a la administración de dichos recursos y más tiempo a centrarse en las aplicaciones que se ejecutan en

AWS. Puede crear una plantilla que describa todos los recursos de AWS que desea (como instancias de Amazon EC2 o instancias de base de datos de Amazon RDS) y CloudFormation se encargará del aprovisionamiento y la configuración de dichos recursos. No es necesario crear y configurar individualmente los recursos de AWS ni averiguar qué depende de qué; CloudFormation se encarga de todo eso.

Una ***plantilla de CloudFormation*** es un archivo de texto que sigue reglas de formato específicas mediante el estándar Notación de objetos JavaScript (JSON) o YAML. Dado que las plantillas son archivos de texto, puede crearlas y editarlas en cualquier editor de texto, además de administrarlas en su sistema de control de código fuente junto con el resto de sus códigos fuente.
En la plantilla, usted declara los recursos de AWS que desea crear. Las plantillas pueden tener varias secciones, pero la única sección necesaria es la sección Resources, que debe declarar al menos un recurso.

Sabiendo ahora en qué consiste AWS CloudFormation, procedamos con el laboratorio de Amazon Redshift.

Dejamos la configuración por defecto y damos clic en Next:

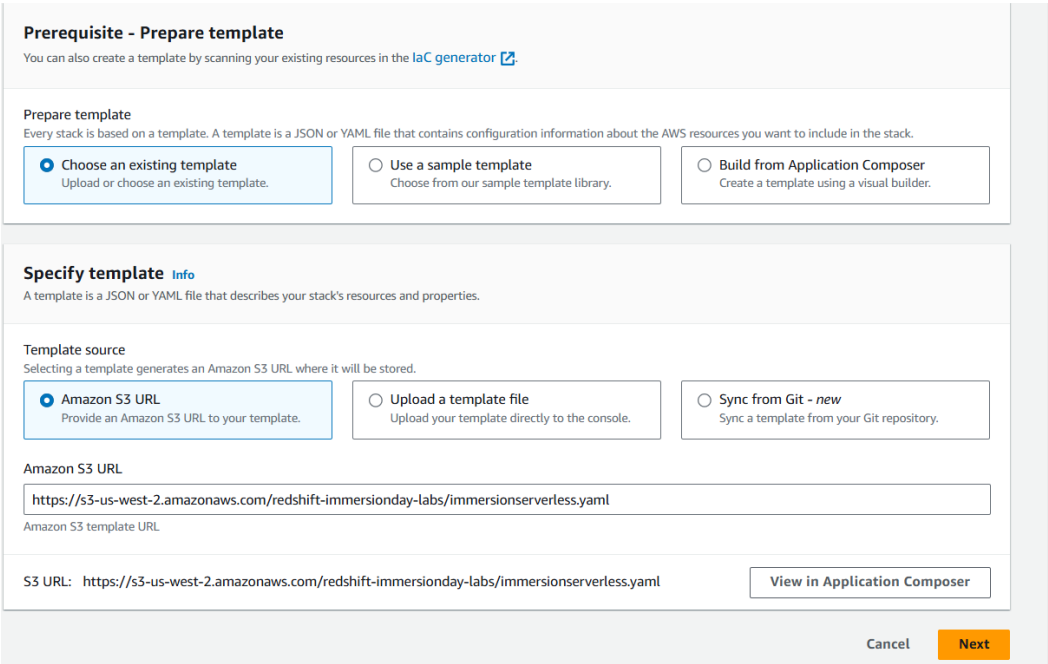

Tenga en cuenta los datos de conexión:

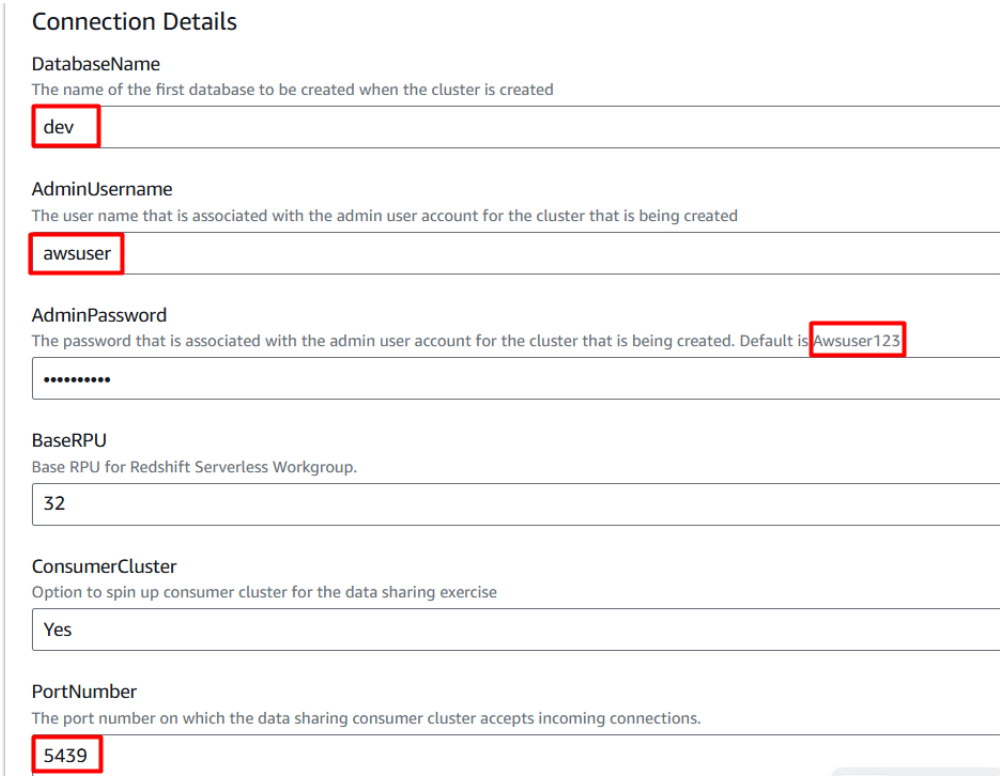

Antes de lanzar el stack (la pila de recursos), debemos activar estas casillas de verificación indicando que conocemos y estamos de acuerdo con los recursos que vamos a desplegar:

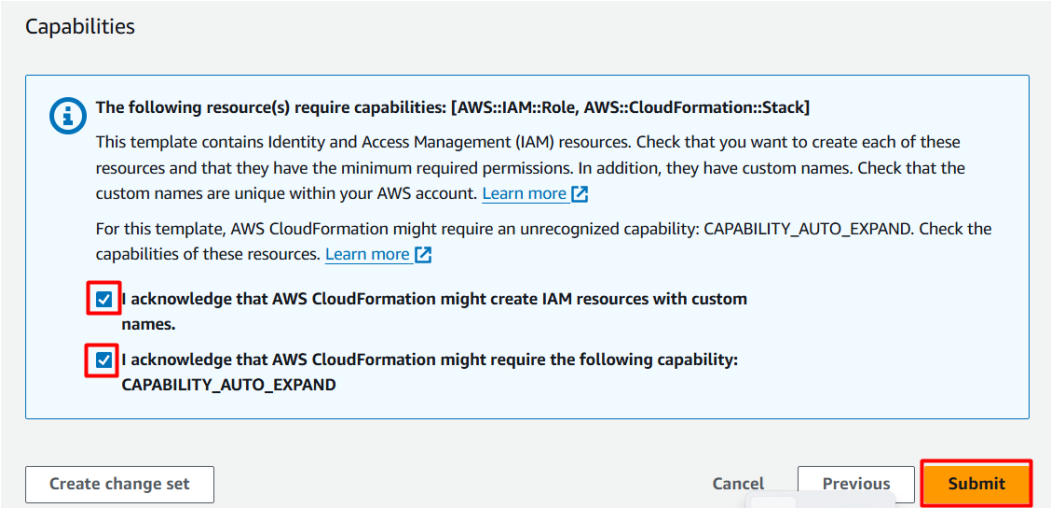

El despliegue del stack puede tardar unos minutos:

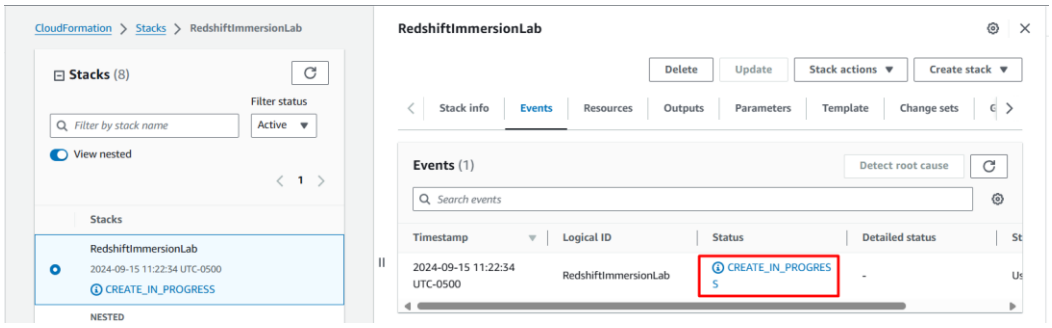

2. Una vez se hayan desplegado los recursos necesarios, navegamos al Editor de consultas v2 https://console.aws.amazon.com/sqlworkbench/home?#/client

   Si es primera vez que usa el editor de consultas, es posible que le solicite configurarlo:

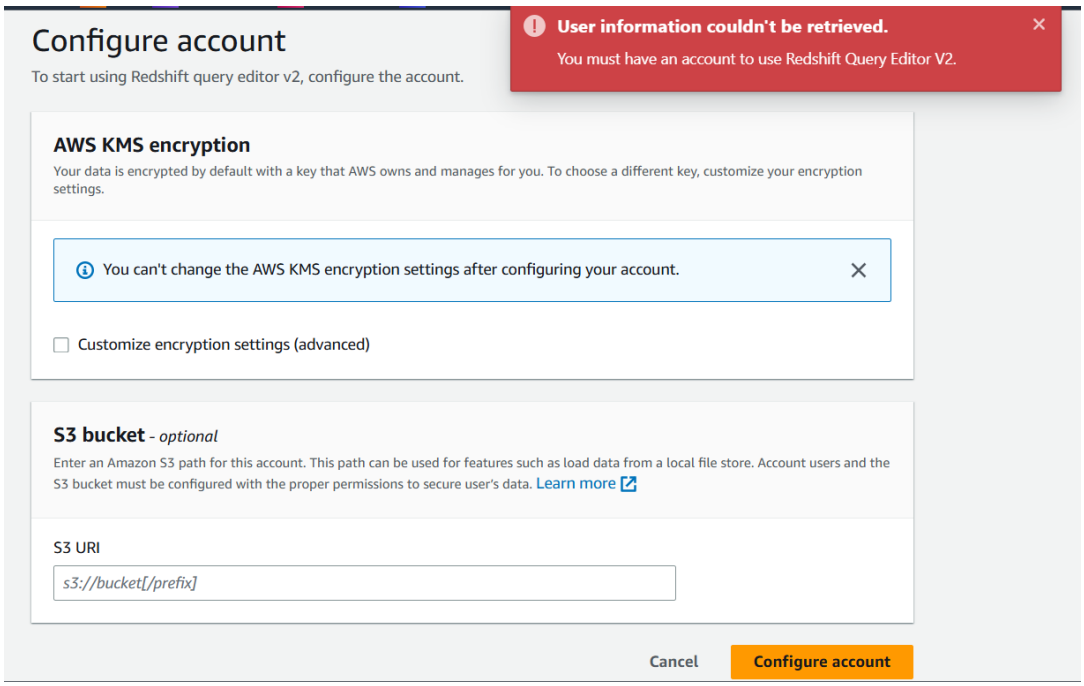

En este laboratorio utilizaremos el Editor de consultas v2 basado en web de Redshift.

En el lado izquierdo, hacemos clic en el entorno de Redshift al que nos vamos a conectar:

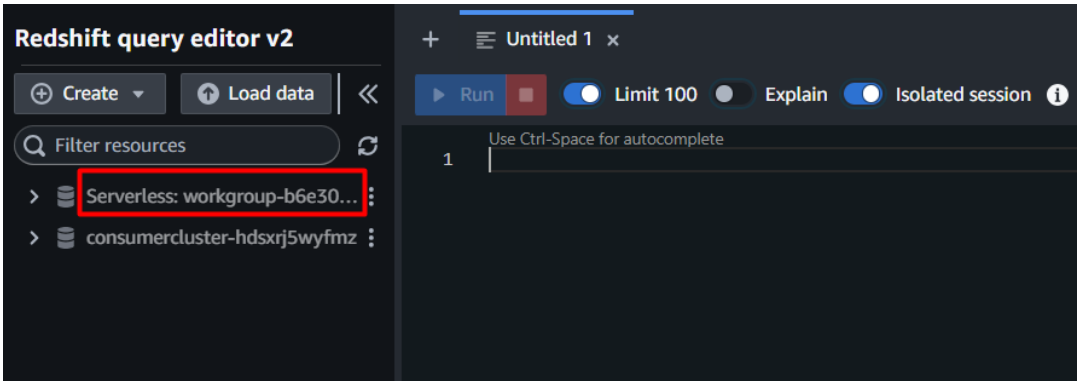

Debe abrirse una ventana emergente, seleccionamos **Database user name and password** y damos clic en **Create connection.**
Ingresamos el usuario y la contraseña que establecimos en los Connection Details:

User Name: **awsuser**
Password: **Awsuser123**

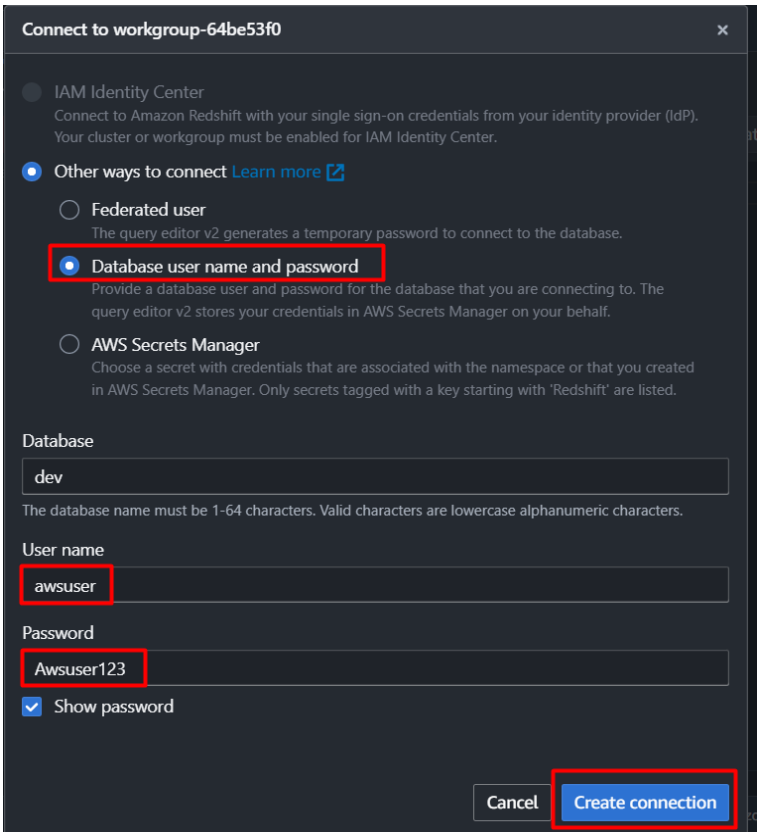

3. Ejecución de una consulta de ejemplo: Ejecute la siguiente consulta para enumerar los usuarios del clúster de redshift: select * from pg_user;

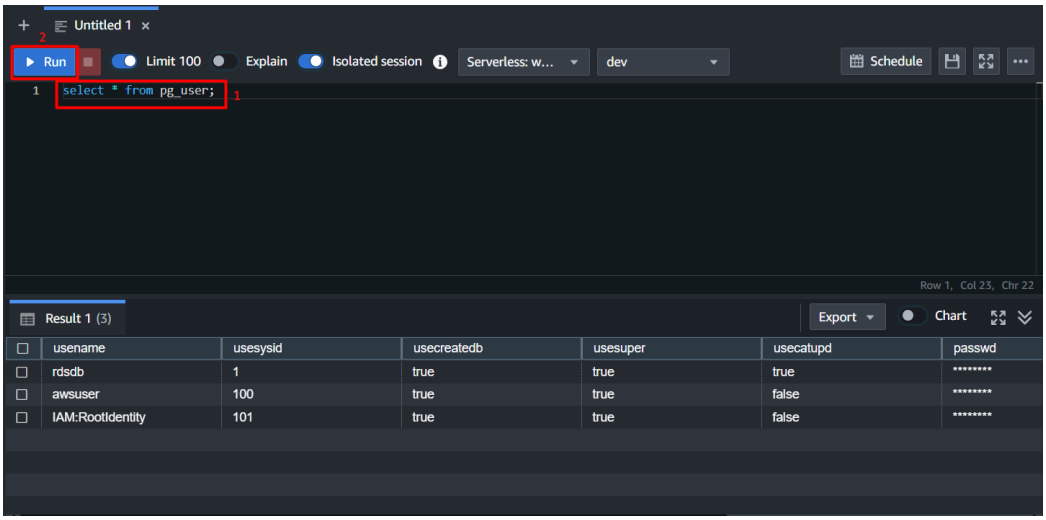

Si recibe estos resultados, significa que ha establecido la conectividad de forma correcta.

4. Crear tablas: Para crear 8 tablas copiamos las siguientes instrucciones y ejecutamos, si estamos siguiendo el link del laboratorio damos clic en el icono de copiar:

```
DROP TABLE IF EXISTS partsupp;
DROP TABLE IF EXISTS lineitem;
DROP TABLE IF EXISTS supplier;
DROP TABLE IF EXISTS part;
DROP TABLE IF EXISTS orders;
DROP TABLE IF EXISTS customer;
DROP TABLE IF EXISTS nation;
DROP TABLE IF EXISTS region;

CREATE TABLE region (
  R_REGIONKEY bigint NOT NULL,
  R_NAME varchar(25),
  R_COMMENT varchar(152))
diststyle all;

CREATE TABLE nation (
  N_NATIONKEY bigint NOT NULL,
  N_NAME varchar(25),
  N_REGIONKEY bigint,
  N_COMMENT varchar(152))
diststyle all;
```

De lo contrario, copiamos y pegamos los siguientes comandos:

DROP TABLE IF EXISTS partsupp;
DROP TABLE IF EXISTS lineitem;
DROP TABLE IF EXISTS supplier;
DROP TABLE IF EXISTS part;
DROP TABLE IF EXISTS orders;

DROP TABLE IF EXISTS customer;
DROP TABLE IF EXISTS nation;
DROP TABLE IF EXISTS region;

CREATE TABLE region (
  R_REGIONKEY bigint NOT NULL,
  R_NAME varchar(25),
  R_COMMENT varchar(152))
diststyle all;

CREATE TABLE nation (
  N_NATIONKEY bigint NOT NULL,
  N_NAME varchar(25),
  N_REGIONKEY bigint,
  N_COMMENT varchar(152))
diststyle all;

create table customer (
  C_CUSTKEY bigint NOT NULL,
  C_NAME varchar(25),

```
  C_ADDRESS varchar(40),
  C_NATIONKEY bigint,
  C_PHONE varchar(15),
  C_ACCTBAL decimal(18,4),
  C_MKTSEGMENT varchar(10),
  C_COMMENT varchar(117))
diststyle all;

create table orders (
  O_ORDERKEY bigint NOT NULL,
  O_CUSTKEY bigint,
  O_ORDERSTATUS varchar(1),
  O_TOTALPRICE decimal(18,4),
  O_ORDERDATE Date,
  O_ORDERPRIORITY varchar(15),
  O_CLERK varchar(15),
  O_SHIPPRIORITY Integer,
  O_COMMENT varchar(79))
distkey (O_ORDERKEY)
sortkey (O_ORDERDATE);

create table part (
  P_PARTKEY bigint NOT NULL,
  P_NAME varchar(55),
  P_MFGR  varchar(25),
  P_BRAND varchar(10),
  P_TYPE varchar(25),
  P_SIZE integer,
  P_CONTAINER varchar(10),
  P_RETAILPRICE decimal(18,4),
  P_COMMENT varchar(23))
diststyle all;

create table supplier (
  S_SUPPKEY bigint NOT NULL,
  S_NAME varchar(25),
  S_ADDRESS varchar(40),
  S_NATIONKEY bigint,
  S_PHONE varchar(15),
  S_ACCTBAL decimal(18,4),
  S_COMMENT varchar(101))
diststyle all;
```

```
create table lineitem (
  L_ORDERKEY bigint NOT NULL,
  L_PARTKEY bigint,
  L_SUPPKEY bigint,
  L_LINENUMBER integer NOT NULL,
  L_QUANTITY decimal(18,4),
  L_EXTENDEDPRICE decimal(18,4),
  L_DISCOUNT decimal(18,4),
  L_TAX decimal(18,4),
  L_RETURNFLAG varchar(1),
  L_LINESTATUS varchar(1),
  L_SHIPDATE date,
  L_COMMITDATE date,
  L_RECEIPTDATE date,
  L_SHIPINSTRUCT varchar(25),
  L_SHIPMODE varchar(10),
  L_COMMENT varchar(44))
distkey (L_ORDERKEY)
sortkey (L_RECEIPTDATE);

create table partsupp (
  PS_PARTKEY bigint NOT NULL,
  PS_SUPPKEY bigint NOT NULL,
  PS_AVAILQTY integer,
  PS_SUPPLYCOST decimal(18,4),
  PS_COMMENT varchar(199))
diststyle even;
```

A continuación, se muestra el modelo de datos para las tablas:

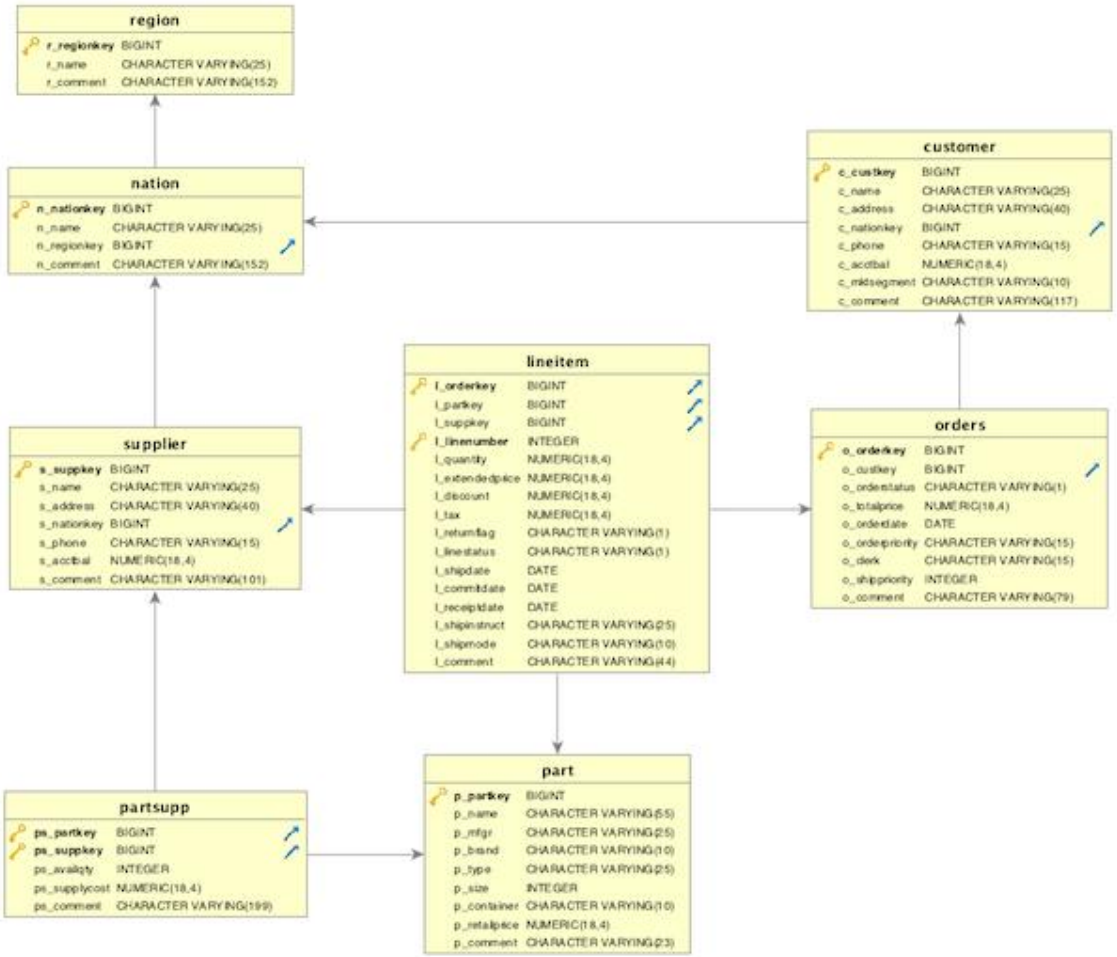

5. Carga de datos: En este laboratorio, aprenderemos dos formas para cargar datos en Redshift.

   - Cargar datos de S3 a Redshift: Utilizaremos este proceso para cargar 7 tablas de las 8 tablas creadas en el paso anterior.

   - Cargar los datos de un archivo local a Redshift. Utilizaremos este proceso para cargar 1 tabla de las 8 creadas en el paso anterior, puntualmente tabla de naciones.

   Carga de datos desde S3: El comando COPY carga grandes cantidades de datos de forma eficaz desde Amazon S3 en Amazon Redshift. Un solo comando COPY puede cargarse desde varios archivos en una tabla. Carga automáticamente los datos en paralelo desde todos los archivos presentes en la ubicación de S3 que proporcione.

Si la tabla de destino está vacía, el comando COPY puede realizar la codificación de compresión para cada columna automáticamente en función del tipo de datos de columna, de modo que no tenga que preocuparse por elegir el algoritmo de compresión adecuado para cada columna. Para asegurarnos de que Redshift realiza un análisis de compresión, vamos a establecer el parámetro COMPUPDATE en PRESET en los comandos COPY.

Los datos de muestra que se van a cargar se ponen a disposición en un Bucket público de Amazon S3:

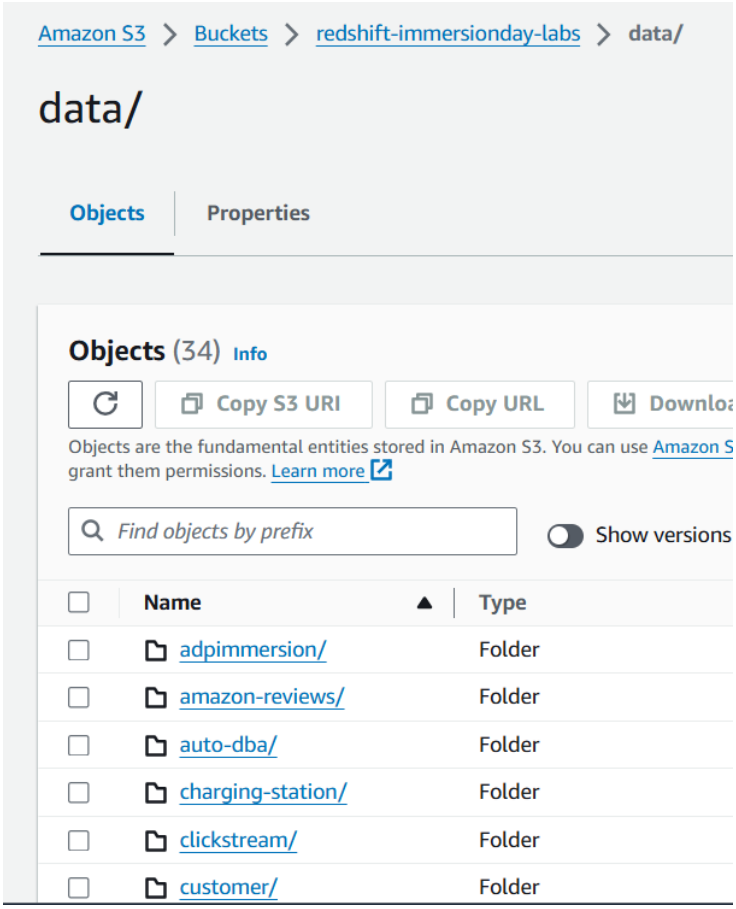

Copie las siguientes instrucciones para cargar datos en 7 tablas:

```
COPY region FROM 's3://redshift-immersionday-labs/data/region/region.tbl.lzo'
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy customer from 's3://redshift-immersionday-labs/data/customer/customer.tbl.'
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy orders from 's3://redshift-immersionday-labs/data/orders/orders.tbl.'
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy part from 's3://redshift-immersionday-labs/data/part/part.tbl.'
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy supplier from 's3://redshift-immersionday-labs/data/supplier/supplier.json' manifest
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy lineitem from 's3://redshift-immersionday-labs/data/lineitem-part/'
iam_role default
region 'us-west-2' gzip delimiter '|' COMPUPDATE PRESET;
```

COPY region FROM 's3://redshift-immersionday-labs/data/region/region.tbl.lzo'
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy customer from 's3://redshift-immersionday-labs/data/customer/customer.tbl.'
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy orders from 's3://redshift-immersionday-labs/data/orders/orders.tbl.'
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy part from 's3://redshift-immersionday-labs/data/part/part.tbl.'
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy supplier from 's3://redshift-immersionday-labs/data/supplier/supplier.json' manifest
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

copy lineitem from 's3://redshift-immersionday-labs/data/lineitem-part/'
iam_role default
region 'us-west-2' gzip delimiter '|' COMPUPDATE PRESET;

copy partsupp from 's3://redshift-immersionday-labs/data/partsupp/partsupp.tbl.'
iam_role default
region 'us-west-2' lzop delimiter '|' COMPUPDATE PRESET;

El tiempo estimado para cargar los datos es el siguiente:

- REGIÓN (5 filas) - 2s
- CLIENTE (15M filas) – 2m
- PEDIDOS - (76M filas) - 10s
- PARTE - (20M filas) - 2m
- PROVEEDOR - (1M filas) - 10s
- LÍNEA DE PEDIDO - (303 millones de filas) - 22 s
- PARTSUPPLIER - (80M filas) - 15s

Mientras esperamos a que finalice el proceso de copia, pasamos a la segunda forma para cargar datos en Redshift.

Carga datos desde su máquina local, mediante QEV2: Cargaremos la tabla de naciones a través del editor de consultas v2 importando los datos desde nuestro equipo local.

Como configuración única, debemos crear un bucket de S3 en la misma región que la instancia de RedShift y agregamos la ruta del bucket de S3 en la página de configuración de la cuenta QEV2.

Este bucket de S3 ya lo creamos en el despliegue de la pila de CloudFormation. Vamos a AWS CloudFormation, hacemos clic en la pila ' RedshiftImmersionLab', en la pestaña Salidas o Outputs, anotamos el valor de la key S3Bucket, es un archivo que necesitaremos en el siguiente paso:

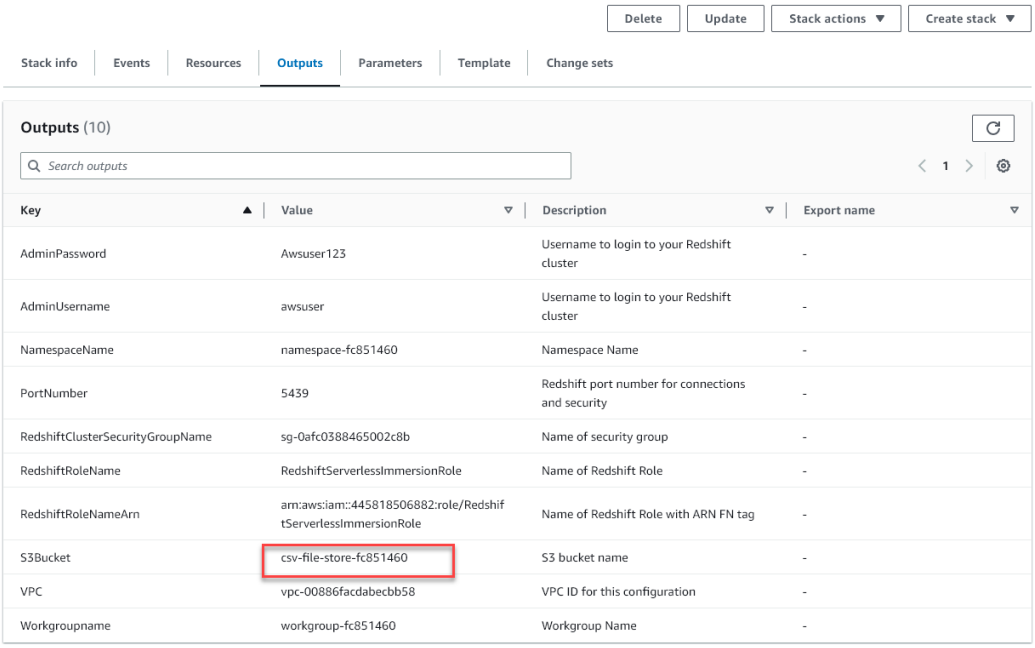

Key	Value	Description	Export name
AdminPassword	Awsuser123	Username to login to your Redshift cluster	-
AdminUsername	awsuser	Username to login to your Redshift cluster	-
NamespaceName	namespace-fc851460	Namespace Name	-
PortNumber	5439	Redshift port number for connections and security	-
RedshiftClusterSecurityGroupName	sg-0afc0388465002c8b	Name of security group	-
RedshiftRoleName	RedshiftServerlessImmersionRole	Name of Redshift Role	-
RedshiftRoleNameArn	arn:aws:iam::445818506882:role/RedshiftServerlessImmersionRole	Name of Redshift Role with ARN FN tag	-
S3Bucket	csv-file-store-fc851460	S3 bucket name	-
VPC	vpc-00886facdabecbb58	VPC ID for this configuration	-
Workgroupname	workgroup-fc851460	Workgroup Name	-

En QEV2, vamos al ícono de Configuración (abajo a la izquierda) y damos clic en Account settings (configuración de la cuenta):

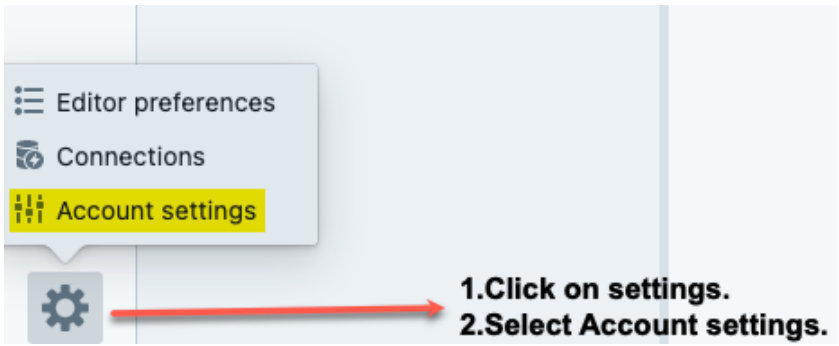

Pegamos el nombre del bucket de S3, que copiamos previamente de las salidas de CloudFormation:

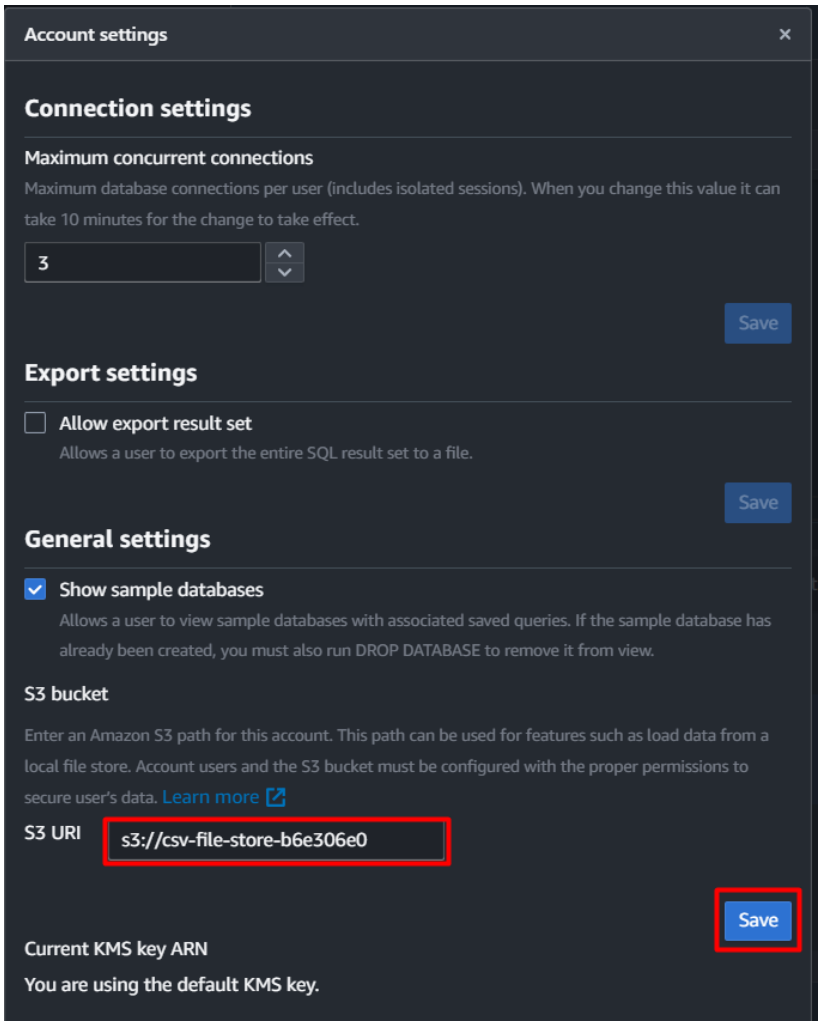

Puede descargar el archivo de Nation.csv de muestra en su máquina local utilizando el siguiente enlace: https://redshift-immersionday-labs.s3.us-west-2.amazonaws.com/data/nation/Nation.csv

Haga clic en **Load Data (Cargar datos)**:

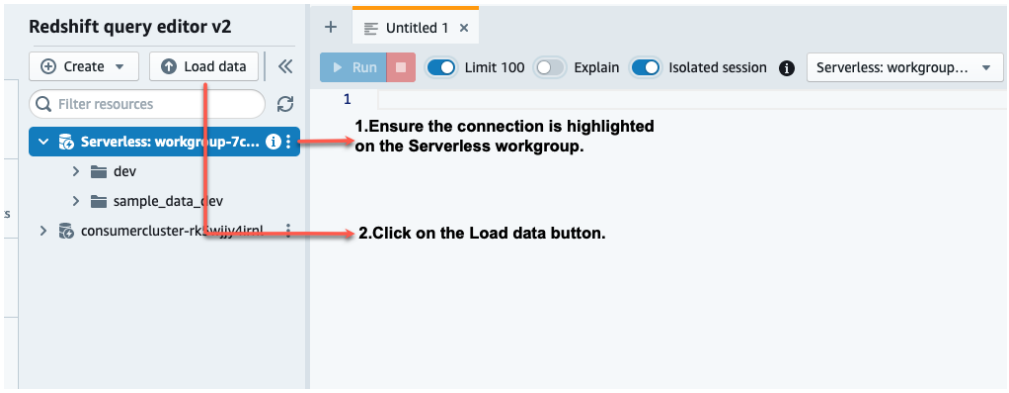

Seleccione **Load from local file** (Cargar desde archivo local) -> Busque y seleccione el archivo Nation.csv descargado anteriormente -> Marque **Ignore header rows** (Ignorar filas de encabezado) -> Clic en **Next**:

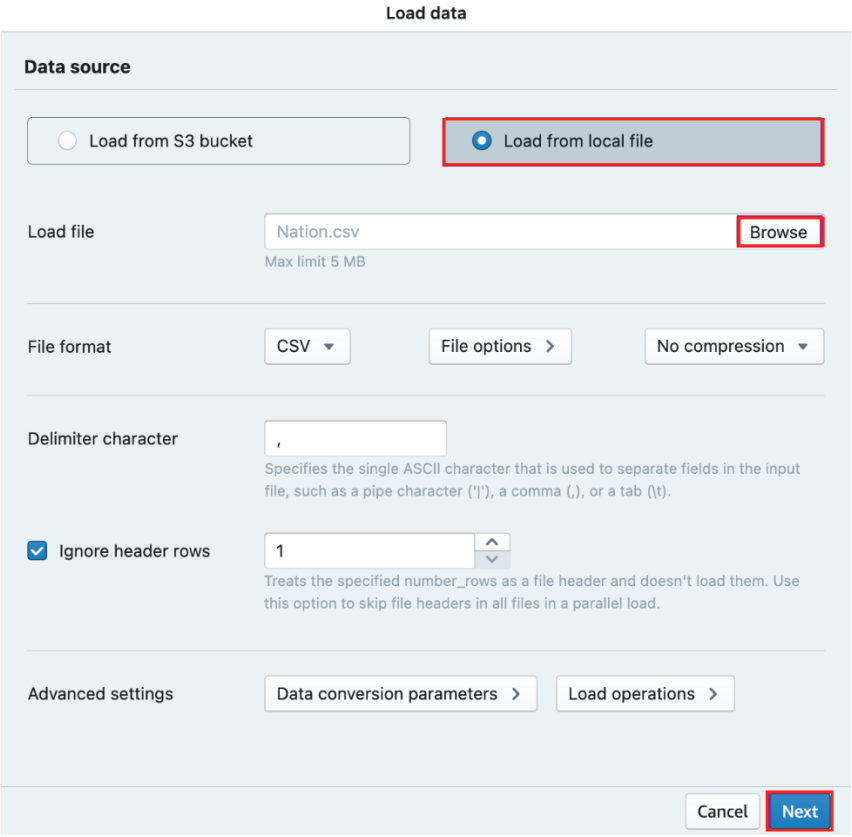

Opciones de tabla: **Seleccione Load existing table** -> Escoja su grupo de trabajo sin servidor -> Base de datos = dev -> Esquema = public -> Tabla = nation -> **Load Data** (Cargar datos):

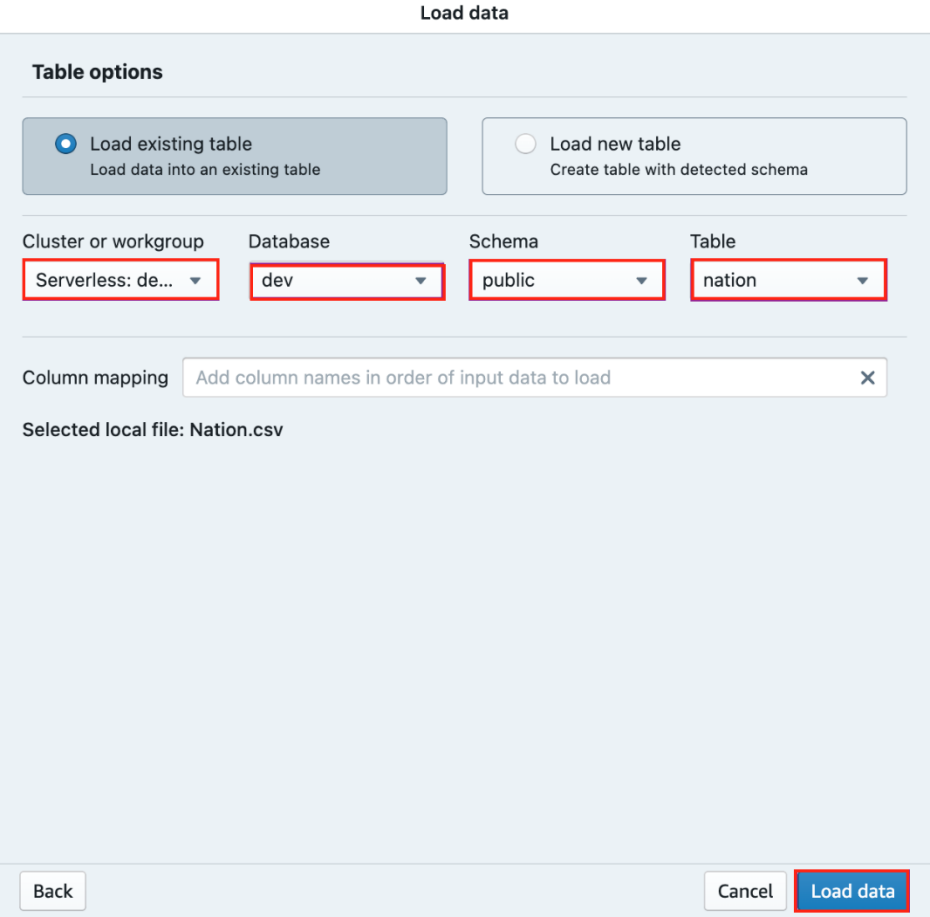

La notificación de que la carga de datos de un archivo local se ha realizado correctamente se mostrará en la parte superior:

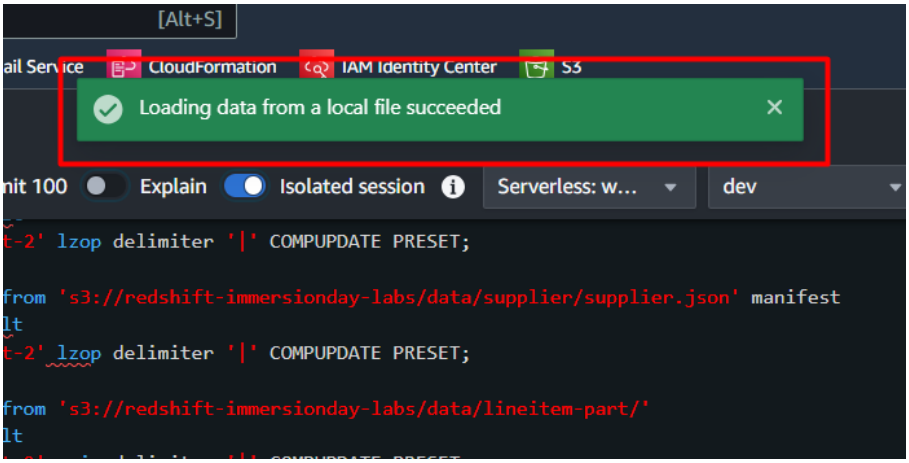

6. Validación de carga: Vamos a hacer una comprobación rápida de los recuentos en algunas tablas para asegurarnos de que los datos se cargaron según lo esperado. En el query editor ejecutamos las siguientes consultas:

```
--Number of rows= 5
select count(*) from region;

--Number of rows= 25
select count(*) from nation;

--Number of rows= 76,000,000
select count(*) from orders;
```

Debemos obtener los resultados para las 3 consultas hechas:

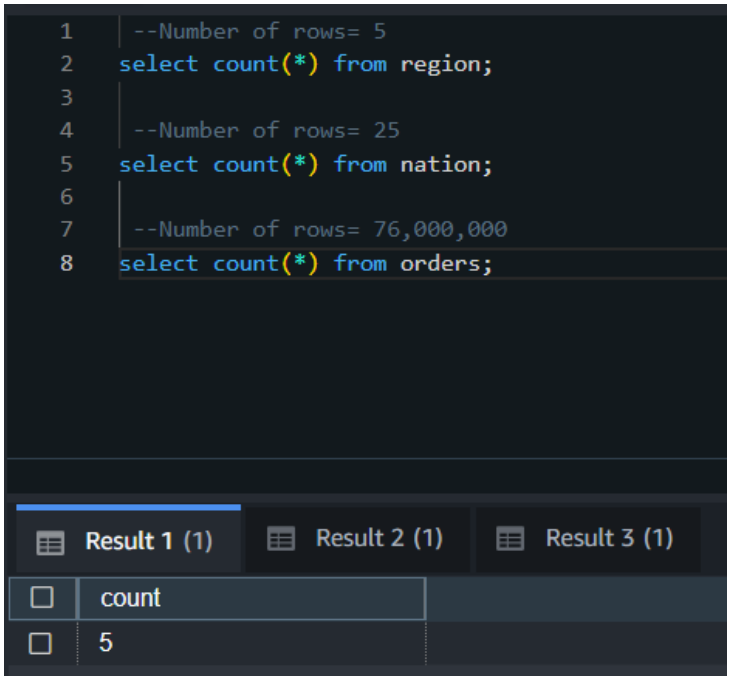

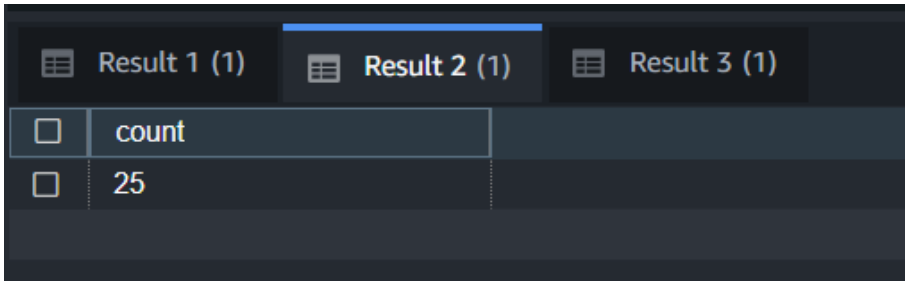

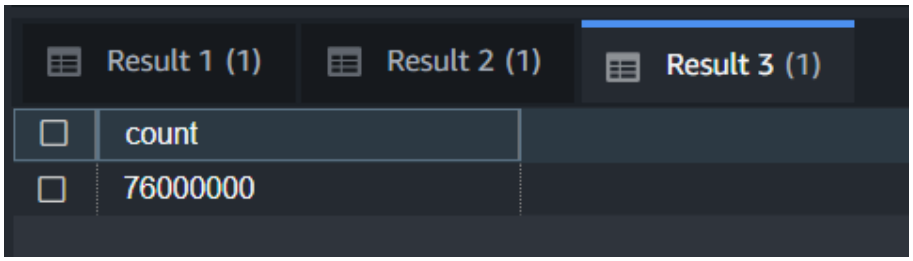

7. Solución de problemas de carga: Para solucionar cualquier problema de carga de datos, puede consultar SYS_LOAD_ERROR_DETAIL.

   Intentemos cargar la tabla CUSTOMER con un archivo de datos diferente con columnas no coincidentes, ejecutando el siguiente comando:

   COPY customer FROM 's3://redshift-immersionday-labs/data/nation/nation.tbl.'
   iam_role default
   region 'us-west-2' lzop delimiter '|' noload;

   Obtenemos el siguiente error:

   ERROR: Load into table 'customer' failed. Check 'sys_load_error_detail' system table for details.

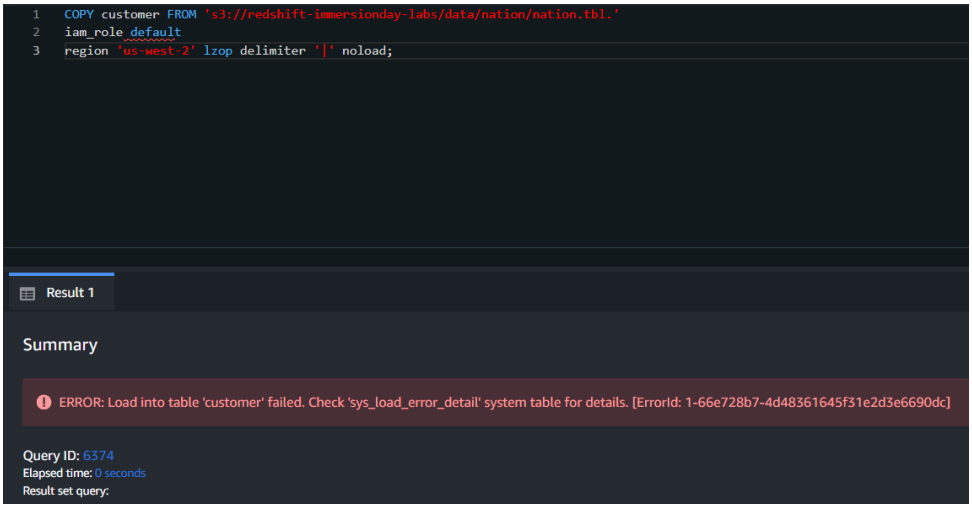

   Consultemos la tabla del sistema STL_LOAD_ERROR para obtener más información:

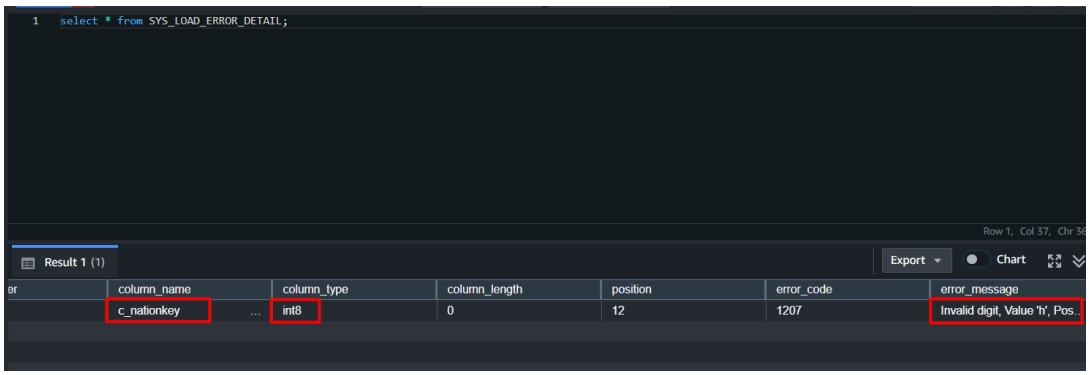

Observamos que hay una fila para la columna c_nationkey con el tipo de datos int con un mensaje de error "Dígito no válido, valor 'h', Pos 1" que indica que estamos intentando cargar caracteres en una columna entera.

8. Mantenimiento automático de la tabla – ANALYZE y VACUUM:

ANALYZE (Analizar): Al cargar en una tabla vacía, el comando COPY recopila estadísticas (ANALYZE) de forma predeterminada. Si está cargando una tabla no vacía mediante el comando COPY, en la mayoría de los casos, no es necesario ejecutar explícitamente el comando ANALYZE. Amazon Redshift monitorea los cambios en la carga de trabajo y actualiza automáticamente las estadísticas en segundo plano. Para minimizar el impacto en el rendimiento del sistema, el análisis automático se ejecuta durante los períodos en los que las cargas de trabajo son ligeras.

Si necesitamos analizar la tabla inmediatamente después de la carga, podemos ejecutar manualmente el comando ANALYZE.

Para ejecutar ANALYZE en la tabla de pedidos, copiamos el siguiente comando y lo ejecutamos:

ANALYZE orders;

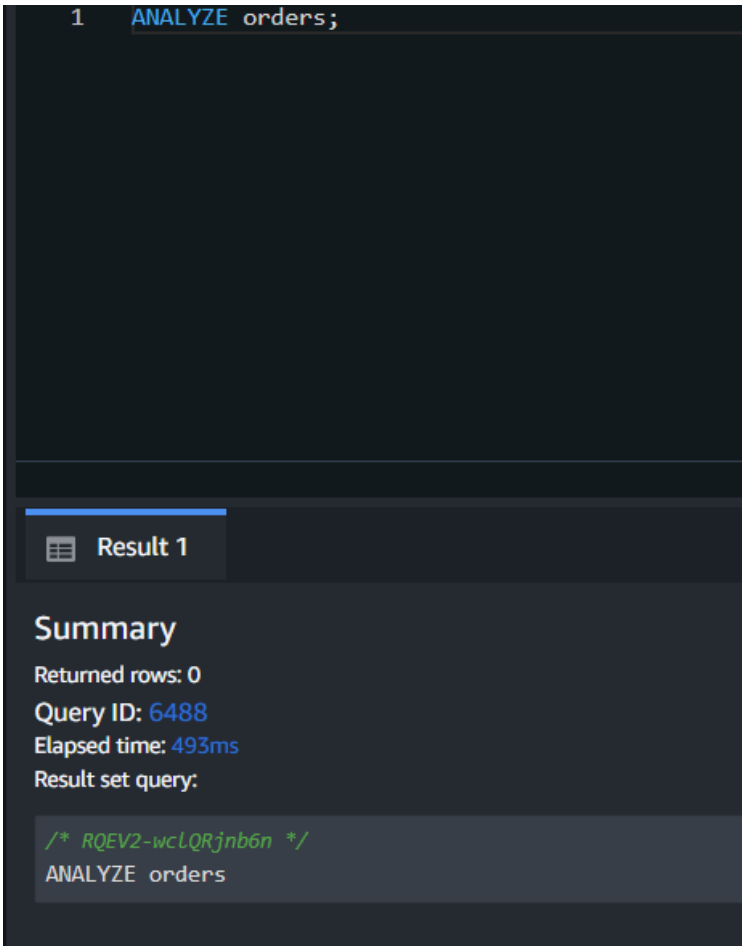

VACUUM (Vaciar): *Eliminación de vacío:* Al realizar la eliminación en una tabla, las filas se marcan para su eliminación (eliminación temporal), pero no se eliminan. Al realizar una actualización, las filas existentes se marcan para su eliminación (eliminación temporal) y las filas actualizadas se insertan como filas nuevas. Amazon Redshift ejecuta automáticamente una operación VACUUM DELETE en segundo plano para recuperar el espacio en disco ocupado por las filas marcadas para su eliminación mediante las operaciones UPDATE y DELETE, y compacta la tabla para liberar el espacio consumido. Para minimizar el impacto en el rendimiento del sistema, VACUUM DELETE automático se ejecuta durante los períodos en los que las cargas de trabajo son ligeras.

Si necesita recuperar espacio en disco inmediatamente después de una operación de eliminación grande, por ejemplo, después de una gran carga de datos, puede ejecutar manualmente el comando VACUUM DELETE. Veamos cómo VACUUM DELETE recupera el espacio de la tabla después de la operación de eliminación.

En primer lugar, capturamos **tbl_rows** (Número total de filas de la tabla. Este valor incluye las filas marcadas para su eliminación, pero que aún no se han limpiado) y **estimated_visible_rows** (Las filas visibles estimadas en la tabla. Este valor no incluye las filas marcadas para su eliminación) de la tabla ORDERS. Copiamos el siguiente comando y lo ejecutamos:

```
select "table", size, tbl_rows, estimated_visible_rows
from SVV_TABLE_INFO
where "table" = 'orders';
```

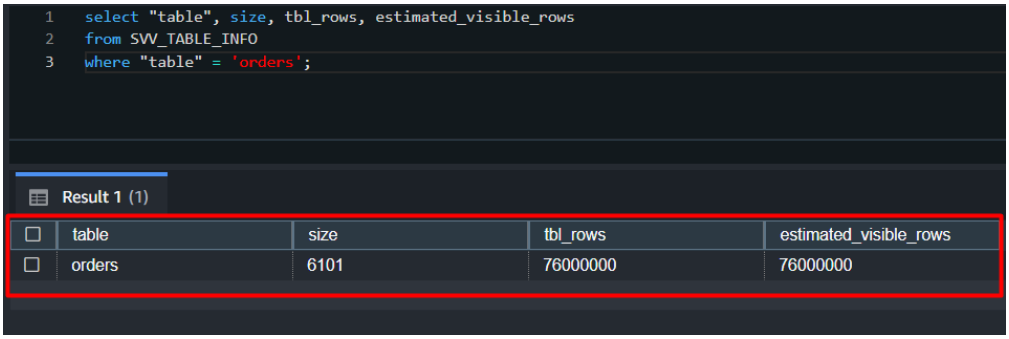

A continuación, eliminamos las filas de la tabla ORDERS. Copiamos y ejecutamos el siguiente comando:

```
delete orders where o_orderdate between '1997-01-01' and '1998-01-01';
```

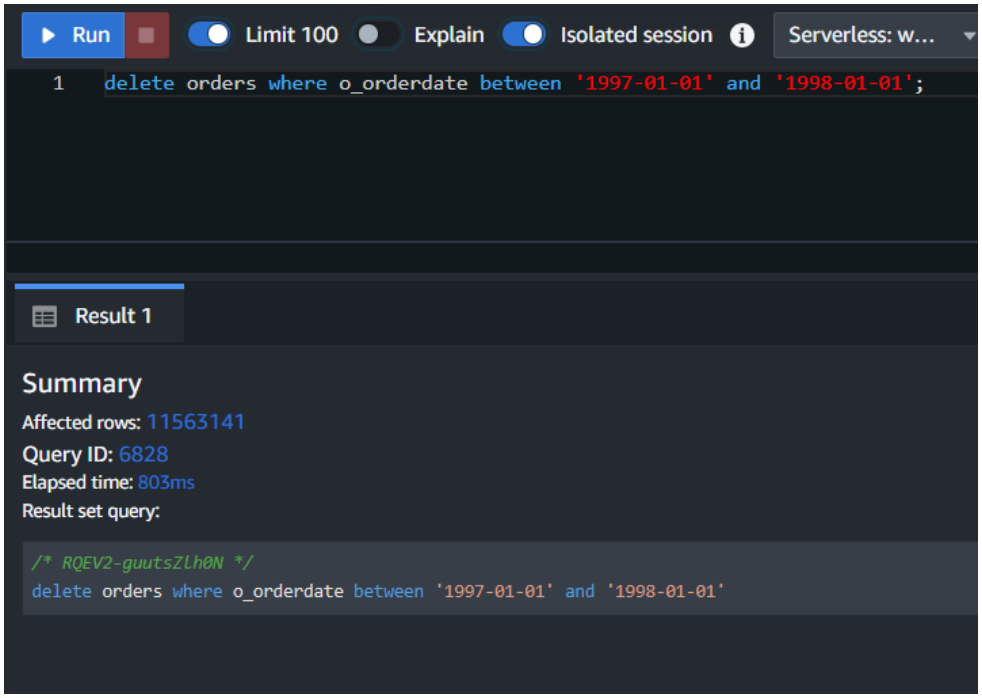

A continuación, capturamos las tablas **tbl_rows** y **estimated_visible_rows** para ORDERS después de la eliminación. Copiamos y ejecutamos el siguiente comando:

```
select "table", size, tbl_rows, estimated_visible_rows
from SVV_TABLE_INFO
where "table" = 'orders';
```

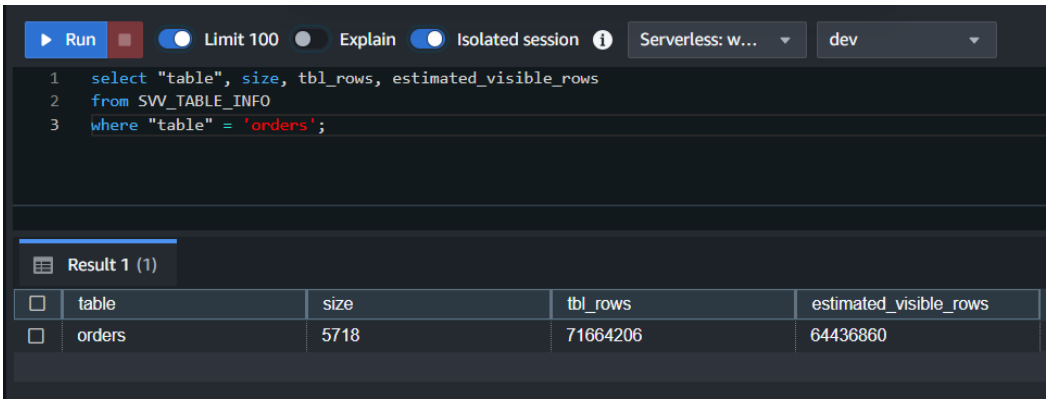

Ahora, ejecutamos el comando VACUUM DELETE:

```
vacuum delete only orders;
```

Confirmamos que el comando VACUUM recuperó espacio ejecutando de nuevo la siguiente consulta y observando que el valor tbl_rows ha cambiado:

```
select "table", size, tbl_rows, estimated_visible_rows
from SVV_TABLE_INFO
where "table" = 'orders';
```

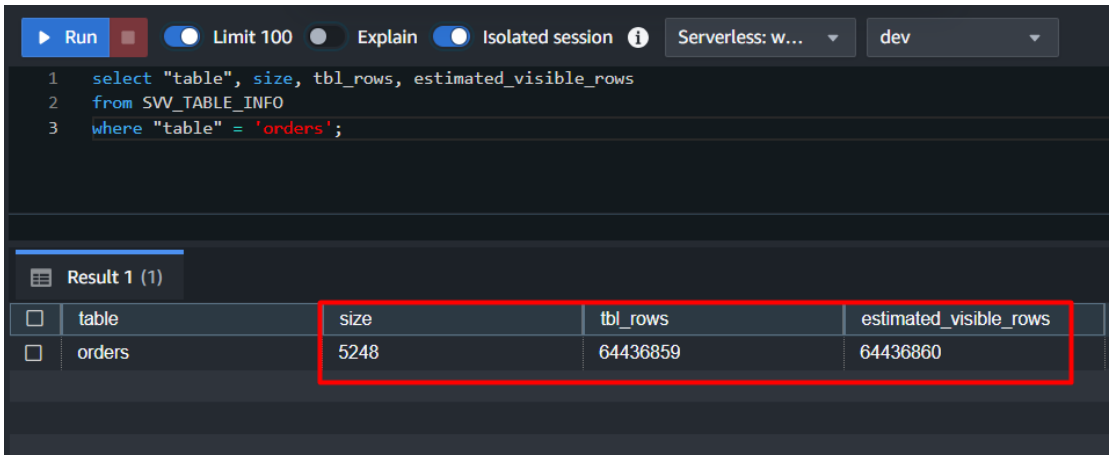

¡Felicitaciones! Obtuviste tu primera experiencia práctica en las funciones clave de Amazon Redshift.

Antes de que te vayas:

9. Limpieza de recursos: Para eliminar los recursos desplegados durante el laboratorio y evitar costos innecesarios, eliminamos la pila de CloudFormation, de esta forma se eliminarán todos los recursos desplegados:

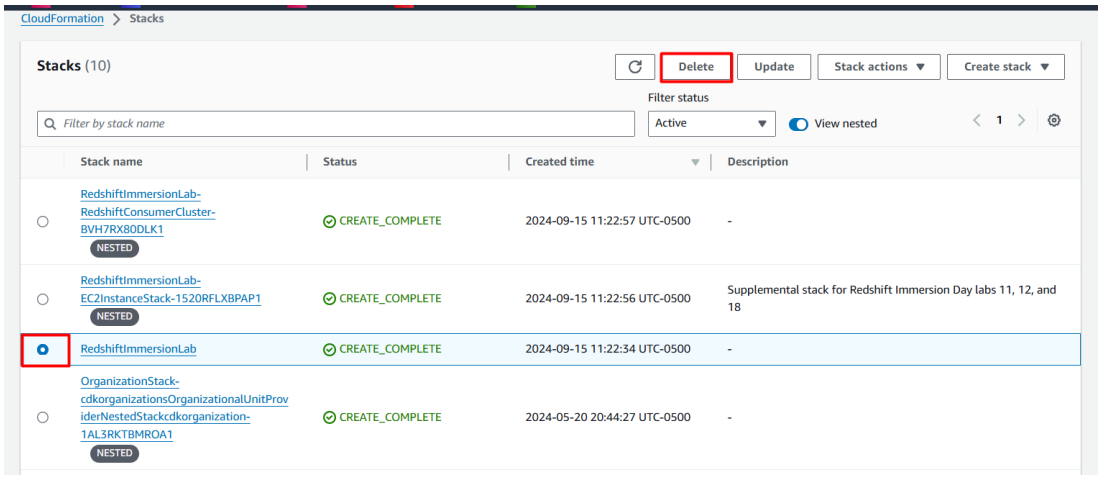
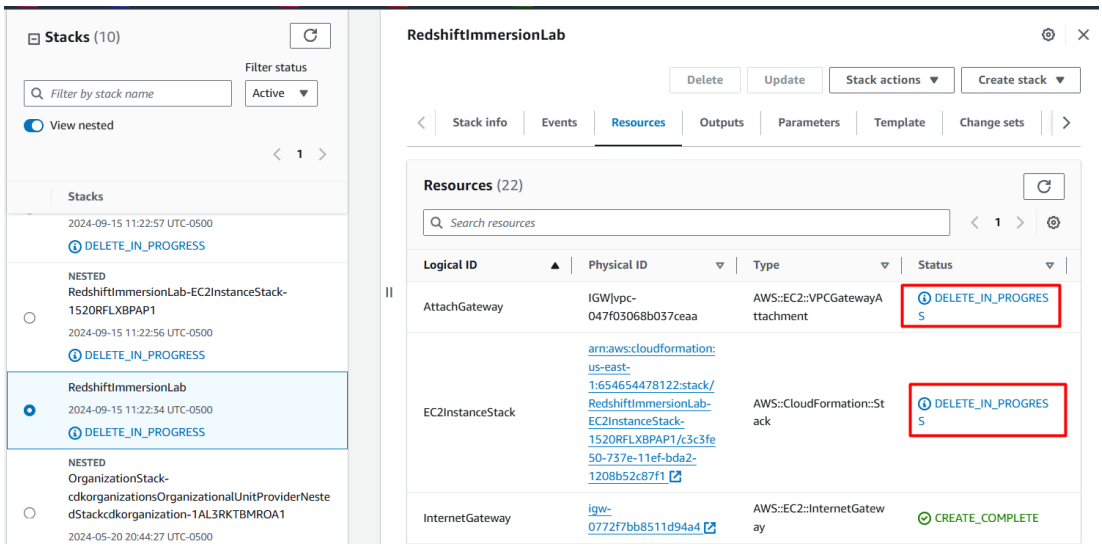
Al igual que el proceso de creación de recursos, el proceso de eliminación también puede tardar algunos minutos.