AMAZON REDSHIFT

CONTENIDO

AMAZON REDSHIFT 2
INTRODUCCIÓN 2
¿QUÉ ES UN DATA WAREHOUSE? 3
BASES DE DATOS BASADAS EN FIILAS Y BASES DE DATOS COLUMNARES 5
BASE DE DATOS BASADA EN FILAS 5
BASE DE DATOS COLUMNAR 6
AMAZON REDSHIFT 7
¿CÓMO FUNCIONA AMAZON REDSHIFT? 7
CARACTERÍSTICAS DE AMAZON REDSHIFT 8
VENTAJAS Y DESVENTAJAS DE AMAZON REDSHIFT 10
CASOS DE USO DE AMAZON REDSHIFT 11

AMAZON REDSHIFT

INTRODUCCIÓN

En clases anteriores vimos bases de datos que pueden manejar miles de transacciones por segundo, almacenamiento de alta disponibilidad y durabilidad masiva, pero a veces tenemos necesidades empresariales que van más allá. Podríamos usar el modelo universal de una única base de datos para todo, pero en las bases de datos modernas diseñadas para alta velocidad, ingesta en tiempo real y de consultas, puede que no sea la mejor opción.

Para manejar la velocidad del tiempo real de la funcionalidad de lectura/escritura, la mayoría de las bases de datos relacionales tienden a funcionar de maravilla en ciertas capacidades. El problema con el análisis teórico, es decir, datos que responden preguntas cómo: "¿Cómo ha mejorado la producción desde que comenzamos como empresa?", es que la recopilación de datos nunca se detiene. De hecho, con la telemetría moderna y la explosión del Internet, el volumen de datos abrumará incluso la base de datos relacional tradicional más fuerte.

No solo el volumen, sino la variedad de datos puede ser un problema. Por ejemplo, si queremos ejecutar proyectos de inteligencia empresarial o BI (business intelligent) con datos procedentes de diferentes almacenes de datos, como el inventario, las finanzas y los sistemas de venta minorista, una sola consulta contra varias bases de datos suena bien, pero las bases de datos tradicionales no las manejan fácilmente.
Una vez que los datos se vuelven demasiado complejo de manejar con bases de datos relacionales tradicionales, entramos en el mundo de los almacenes de datos. Los almacenes de datos están diseñados específicamente para este tipo de big data, donde se revisan análisis históricos en lugar de análisis operativos.

Histórico puede ser tan pronto como las cifras de ventas de la última hora en todos los almacenes. La clave es que los datos ya están configurados, no estamos vendiendo más desde la última hora, porque eso es cosa del pasado. Compare esa pregunta con: "¿Cuántas bolsas de café tenemos todavía en nuestro inventario en este momento?" Lo que podría estar cambiando justo en el momento de la pregunta. Siempre y cuando la pregunta mire completamente hacia atrás, entonces, un almacén de datos es la solución adecuada para esa línea de inteligencia empresarial.

Hay muchas soluciones de almacén de datos en el mercado. Si ya tiene uno de sus favoritos ejecutándose en AWS, solo es cuestión de transferir los datos. Pero más allá de eso, puede haber mucho trabajo pesado que se necesita para mantener un almacén de datos ajustado,

resiliente y con escalado continuo. Para ello está Amazon Redshift, para que su equipo de almacenamiento de datos se centre en los datos en lugar del cuidado y el mantenimiento del motor de base de datos.
Pero es más que poder manejar conjunto de datos enormemente más grandes, Redshift utiliza una variedad de innovaciones que le permiten alcanzar un rendimiento hasta 10 veces mayor que las bases de datos tradicionales, cuando se trata de este tipo de cargas de trabajo de inteligencia empresarial.

Amazon Redshift es un servicio de almacenamiento de datos que puede utilizarse para el análisis de big data. Ofrece la capacidad de recopilar datos de muchas fuentes y ayuda a comprender las relaciones y las tendencias de los datos.

¿QUÉ ES UN DATA WAREHOUSE?

Un data warehouse es un almacén de datos, una estructura analítica, que recibe información de muchas fuentes de datos.
Su objetivo es unificar/centralizar la información para ayudar a la analítica de la empresa, no mantiene operaciones constantes del negocio, sino que está orientado a la analítica de datos.

¿Cómo debería funcionar un data warehouse? Debo tomar toda la data que es útil a mi negocio y llevarla a ese único repositorio.

¿Cómo me llevo los datos al data warehouse? Por medio de ETL, es decir, extracción, transformación y carga, entonces tenemos múltiples procesos ETL alimentando el data warehouse.

Extraer: Obtener los datos de las distintas fuentes.

Fuentes: Sistemas transaccionales como SAP, aplicaciones empresariales como CRM, tablas de Excel, información de bases de datos, archivos planos, etc.

Tipos de datos: Estructurados, no estructurados y metadatos (datos que describen otros datos).

Transformar: Realizar una limpieza y modificación de los datos, creando una buena estructura analítica.

Cargar: Luego de transformar los datos, se cargan al data warehouse.

El fin de una data warehouse no es simplemente almacenar datos, para almacenamiento de datos tenemos a Amazon S3.
No es solo consultar datos o hacer queries sencillos, para eso podemos usar una base de datos relacional, como Amazon RDS, o si los datos están en Amazon S3 podemos hacer queries a demanda con Amazon Athena.
El fin de un data warehouse es la analítica de datos, es decir, extraer información valiosa a partir de datos crudos, revelando patrones y tendencias que ayudan en la toma de decisiones basada en datos.

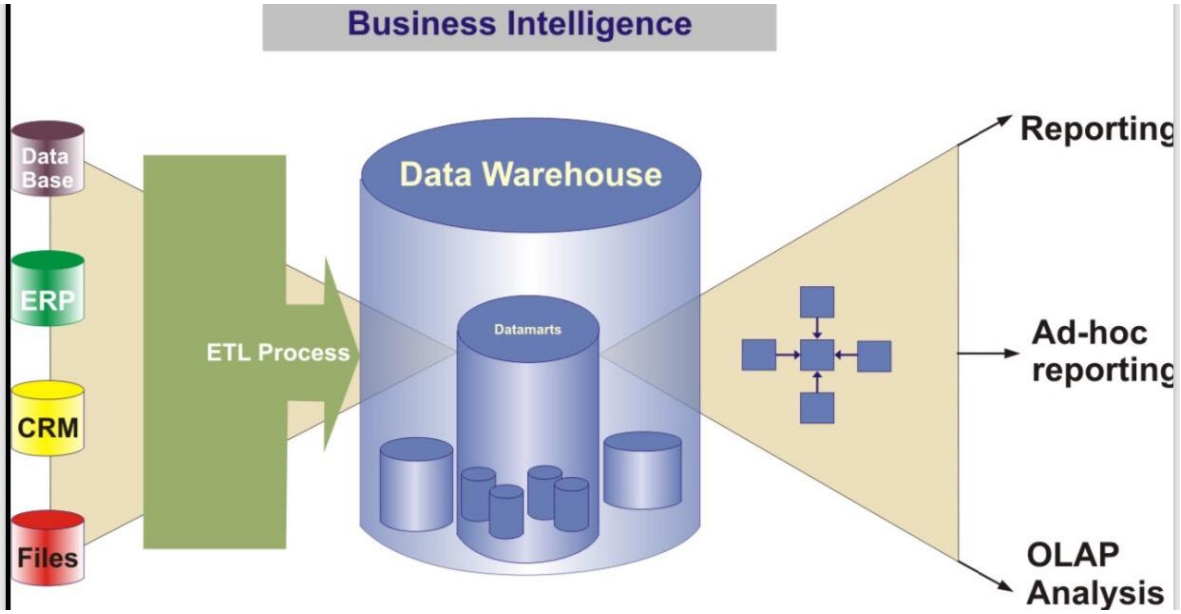

En síntesis, un data warehouse es una estructura analítica, que no mantiene operaciones/transacciones constantes del negocio, sino que está orientado a la analítica de datos.

Y entonces, ¿Qué es una estructura analítica? Depende de la organización, pero el estándar es el modelo dimensional, que posee:

Tabla de hechos: Qué quiero medir.

Tabla de dimensiones: Cómo medirlo, es decir, qué variables son importante para generar los análisis.

BASES DE DATOS BASADAS EN FIILAS Y BASES DE DATOS COLUMNARES

Existen dos enfoques principales para almacenar datos en bases de datos: Basado en filas y basado en columnas.

BASE DE DATOS BASADA EN FILAS:

Las bases de datos basadas en filas están orientadas a OLTP (Procesamiento de transacciones en línea), el cual es un sistema de gestión de bases de datos que se utiliza para sistemas transaccionales. Las bases de datos OLTP están diseñadas para registrar y administrar transacciones diarias en tiempo real.
En términos sencillos, OLTP permite la ejecución en tiempo real de una gran cantidad de transacciones de bases de datos realizadas por un gran número de personas, generalmente a través de Internet. Cada transacción puede ser un cambio, inserción, supresión o consulta en una base de datos.

Ejemplos de transacciones OLTP:

- Transacciones en cajeros automáticos y banca en línea, como retiros de efectivo, transferencias y consultas de saldo.

- Comercio electrónico, como compras en línea y transacciones de pago.

- Reservas de hotel y aerolíneas para registrar reservas y cambios de itinerario.

- Incluso las interacciones no financieras se gestionan mediante OLTP, como cambios de contraseña y mensajes de texto

Las bases de datos basadas en filas soportan toda la operación transaccional del negocio, como MySQL, Oracle, PostgreSQL, que procesan muchísimas transacciones de manera rápida.

Ejemplo de datos de una base de datos orientada a filas:

Número	Apellido	Nombre	Clave
1.	Skywalker	Luke	3FN-Z768
2	Kenobi	Obi-wan	7TR-K345
3	Organa	Leia	8NN-R266

En este formato, todo el registro se almacena en un bloque. Por ejemplo, si tenemos una tabla de Usuarios, el apellido del usuario, el nombre del usuario y la contraseña del usuario se almacenan juntos en un solo bloque.

BASE DE DATOS COLUMNAR:

Una base de datos columnar es un modelo que organiza los datos en columnas, en lugar de filas. Cada columna contiene datos de un solo tipo y las filas contienen un conjunto de valores correspondientes a esas columnas.

Este enfoque es rápido para consultas analíticas como sumas o promedios, ya que toda la información relevante está en un solo bloque.
Además, las bases de datos en columnas son adecuadas para la compresión eficiente de datos, ya que cada bloque contiene el mismo tipo de datos.

Se usan para consultas complejas de grandes lotes de datos de la manera más eficiente y para procesar queries complejos de grandes cantidades de datos con un fin analítico.
Procesan grandes cantidades de información y se encuentran optimizadas para procesos de analítica.

Ejemplo de datos de una base de datos columnar:

Número	1.	2.	3.
Apellido	Skywalker	Kenobi	Organa
Nombre	Luke	Obi-wan	Leia
Clave	3FN-Z768	7TR-K345	8NN-R266

La base de datos columnar gira la base de datos. Aquí, las columnas enteras se escriben dentro de un bloque. Por ejemplo, todos los apellidos de los usuarios se almacenan juntos en un bloque, todos los nombres de los usuarios en otro bloque y todas las claves de los usuarios se almacenan juntos en un solo bloque.

En el disco duro, sin embargo, los datos se muestran unidimensionales, es decir, se representan de forma sucesiva. Par las bases de datos orientas a filas esto significa lo siguiente:

```
1, Skywalker, Luke, 3FN-Z768; 2, Kenobi, Obi-wan, 7TR-K345; 3, Organa, Leia, 8NN-R266
```

La base de datos columnar también almacena la información de forma sucesiva, pero al organizar los datos de otra forma también resulta una secuencia de datos distinta:

```
1, 2, 3; Skywalker, Kenobi, Organa; Luke, Obi-wan, Leia; 3FN-Z768, 7TR-K345, 8NN-R266
```

AMAZON REDSHIFT

Amazon Redshift es un servicio de almacenamiento de datos administrado a escala de petabytes en la nube. Permite acceder a los datos y analizarlos sin todas las configuraciones de un almacenamiento de datos aprovisionado. En otras palabras, es como un rascacielos digital donde podemos guardar desde simples datos hasta complejas estructuras y consultarlos a gran velocidad. Funciona como un almacén de datos en la nube que permite realizar consultas analíticas en SQL para big data de manera eficiente.

Redshift es un servicio compuesto por clústeres (conjuntos de nodos de cómputo y almacenamiento) donde podemos hacer inteligencia de negocios, más conocida data warehousing o bodegas de datos.
En Redshift podemos almacenar petabytes de datos, procesarlos y hacer queries muy complejos, que junten información de diferentes fuentes de datos, como bases de datos lago de datos, y hacer joins (combinar datos de varias tablas relacionadas) para hacer inteligencia de negocios y analítica en tiempo real.

Redshift utiliza SQL para analizar datos estructurados y semiestructurados de almacenamientos de datos, de bases de datos operativas y de lagos de datos. Ofrece alto rendimiento al mejor precio y a gran escala, con hardware y machine learning diseñado por AWS.
Frente a soluciones on premise, puede ofrecer 10 veces más de rendimiento con un factor de 5 veces más costo eficiencia y, como está en la nube, lo podemos integrar con el resto de más de 200 servicios que tiene AWS.

¿CÓMO FUNCIONA AMAZON REDSHIFT?

Amazon Redshift utiliza una arquitectura de procesamiento paralelo masivo (MPP), que analiza datos mediante múltiples nodos en paralelo, consta de varios nodos de Elastic Compute Cloud (EC2) y permite una ejecución rápida de consultas complejas en grandes cantidades de datos, mediante la distribución del procesamiento de la consulta a múltiples nodos y unidades de procesamiento virtuales dentro de cada nodo de su almacén de datos.

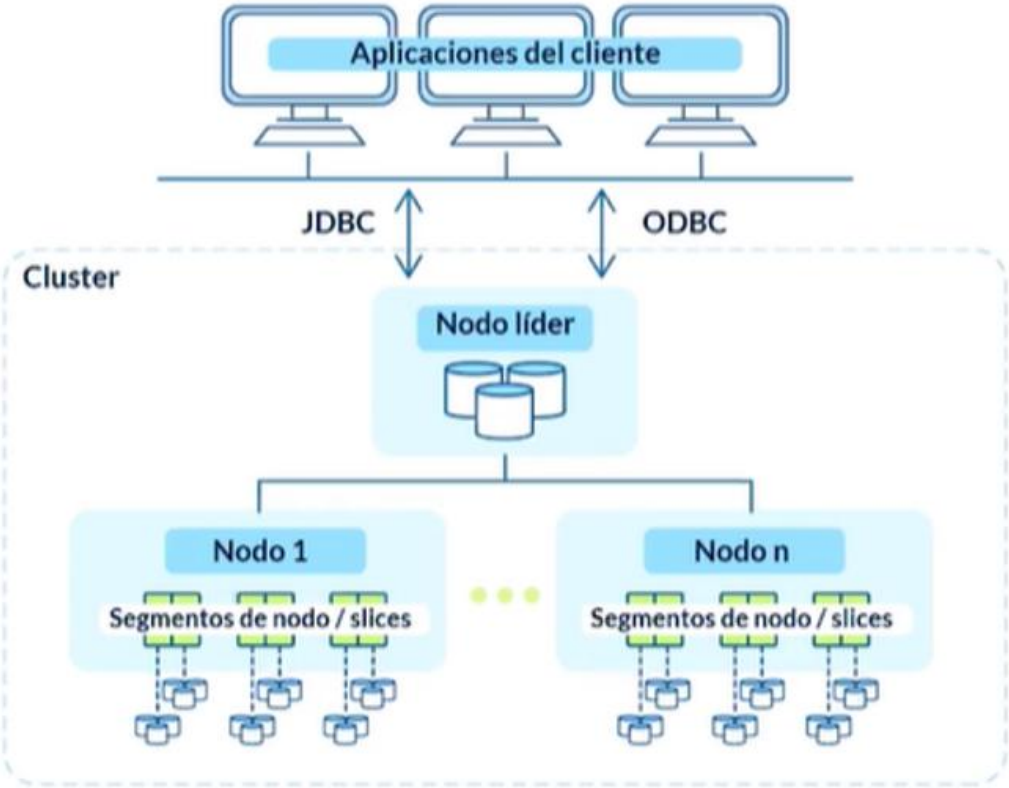

El secreto de Redshift para procesar grandes cantidades de datos es repartir el trabajo. Redshift no se instala en un único servidor, sino que se instala en un clúster (arreglos de varios servidores conectados {NODOS}). Nos conectamos a un nodo líder el cual organiza y asigna las tareas a los otros nodos, llamados nodos seguidores, y cada nodo seguidor reparte su tarea entre sus slices para trabajar la tarea asignada por el nodo líder en paralelo. Es decir que, el nodo líder me orquesta los procesos.

Un slice es una tabla interna en Redshift que se utiliza para mapear sectores a nodos. Cada nodo en el clúster tiene varios slices, y cada slice es responsable de procesar una parte específica de los datos

En resumen, Amazon Redshift es un repositorio unificado de datos con un propósito analítico.

CARACTERÍSTICAS DE AMAZON REDSHIFT

Amazon Redshift cumple las necesidades de un almacenamiento de datos en la nube moderno, altamente escalable, eficiente y confiable para gestionar los datos crecientes de cualquier número de usuarios simultáneos. Aquí están algunas de sus características clave:

Escalabilidad: Amazon Redshift puede manejar enormes cantidades de datos, desde terabytes hasta petabytes. Puede escalar vertical y horizontalmente según sus necesidades. Ejecute y escale cualquier tipo de carga de trabajo de análisis de forma rentable sin tener que gestionar la infraestructura de almacenamiento de datos con Amazon Redshift sin servidor, que incluye escalado y optimizaciones basadas en IA.

Totalmente administrado: Amazon Redshift es un servicio completamente administrado por AWS. No necesita preocuparse por la infraestructura subyacente ni por las tareas de mantenimiento.

Arquitectura MPP (Procesamiento Paralelo Masivo): Con la mejor relación precio-rendimiento para sus cargas de trabajo, Amazon Redshift se ejecuta en una arquitectura de procesamiento paralelo masivo (MPP) e instancias RA3 para distribuir y procesar consultas de manera eficiente en clústeres de nodos, que separan la computación y el almacenamiento.

Sin ETL (Extract, Transform, Load): Redshift permite la interoperabilidad entre diferentes fuentes de datos, como Amazon S3, bases de datos operativas y servicios de transmisión. Esto elimina la necesidad de crear canalizaciones de datos complejas para mover datos entre sistemas.

Precio-rendimiento: Ofrece una excelente relación precio-rendimiento para cargas de trabajo analíticas. Puede iniciar desde $0.25 por hora sin contratos a tiempo específico y escalar hasta petabytes por $1000 por terabyte por año.

Seguridad: Comparta datos de forma segura entre las regiones, los equipos y los almacenamientos de datos de terceros de AWS sin necesidad de mover ni copiar datos. Con solo unos clics, varios equipos pueden leer y actualizar conjuntos de datos compartidos y colaborar para obtener datos actualizados en todas las regiones, cuentas e incluso almacenamientos de datos de terceros. El intercambio de datos se rige de forma centralizada por AWS Lake Formation. Tenga la confianza de que sus datos están seguros sin importar dónde opere o qué tan regulados estén sus sectores. Amazon Redshift permite controles de acceso detallados, como controles de acceso basados en roles, seguridad a nivel de filas y columnas y una experiencia de autenticación sencilla con inicio de sesión único para la identidad de su organización, todo ello sin costo adicional.

Alta disponibilidad: A medida que se adapta a las exigentes necesidades de análisis de su empresa, es imprescindible contar con un almacenamiento de datos en la nube fiable como Amazon Redshift para minimizar las interrupciones gracias a las SLA de despliegue multi-AZ que ofrecen que ofrecen acuerdos de nivel de servicio del 99,99 %.

Análisis y ML integrados: Desde la ejecución de consultas SQL hasta la creación de paneles complejos o aplicaciones de inteligencia artificial e IA generativa casi en tiempo real, Amazon Redshift le facilita el análisis de todos los datos y el impulso de su negocio. Puede poner en marcha un punto de conexión Redshift sin servidor en cuestión de segundos y utilizar Amazon Redshift Query Editor para cargar, analizar y visualizar sus datos en distintos orígenes de datos y colaborar en ellos. Envíe solicitudes de consulta en un lenguaje sencillo y reciba recomendaciones de código SQL personalizadas basadas en los metadatos del esquema de su organización con el SQL generativo de Amazon Q en Query Editor. Pase sin problemas de los datos al análisis predictivo con Amazon Redshift ML, que utiliza el conocido SQL para crear, entrenar e implementar modelos de machine learning o de previsión, directamente en el almacenamiento.

VENTAJAS Y DESVENTAJAS DE AMAZON REDSHIFT

Las ventajas de Amazon Redshift incluyen:

- Rendimiento rápido: Redshift es una de las soluciones más rápidas disponibles actualmente. Carga datos y realiza consultas analíticas o de informes a velocidades impresionantes gracias a su arquitectura MPP (Procesamiento Masivamente Paralelo).

- Alto rendimiento: Su diseño permite aprovechar la paralelización en operaciones de copia de seguridad, restauración y carga de datos. Además, ofrece tasas eficientes de compresión de datos.

- Integración con AWS: Redshift se integra perfectamente con otros servicios de AWS, como Amazon S3 o AWS Glue.

- Costo asequible: Es mucho más económico que competidores como Teradata y Oracle, costando solo una fracción de su precio.

Las desventajas de Amazon AWS Redshift son:

- Complejidad inicial: Configurar y optimizar Redshift puede ser complicado al principio.

- Costos de almacenamiento: Aunque es más asequible que otras soluciones, los costos de almacenamiento pueden aumentar con el tiempo, a medida que aumenta el tamaño de los datos.

- Limitaciones en tipos de datos: Algunos tipos de datos no están disponibles en Redshift, lo que podría afectar ciertas aplicaciones.

CASOS DE USO DE AMAZON REDSHIFT

Amazon Redshift es una poderosa herramienta que se adapta a diversos casos de uso. Algunos ejemplos incluyen:

1. **Análisis de Datos en Tiempo Real**: Amazon Redshift es ideal para analizar grandes volúmenes de datos en tiempo real. Puede procesar consultas complejas y proporcionar resultados rápidos.

2. **Generación de Informes**: Redshift permite crear informes y paneles de control a partir de datos almacenados en el almacén de datos. Esto es útil para tomar decisiones basadas en información actualizada.

3. **Análisis de Negocios**: Las empresas pueden utilizar Redshift para analizar tendencias, patrones y métricas comerciales. Esto ayuda a comprender mejor el rendimiento y tomar decisiones informadas.

4. **Análisis de Registros**: Redshift es eficaz para analizar registros de aplicaciones, servidores web o sistemas. Puede extraer información valiosa de los registros para mejorar la eficiencia y la seguridad.

5. **Personalización de Contenido**: Redshift se puede utilizar para segmentar y personalizar contenido para usuarios específicos. Esto es útil en aplicaciones web y marketing.

Amazon Redshift es versátil y se adapta a una variedad de necesidades empresariales.

En resumen, Amazon Redshift es una solución potente y flexible para el análisis de datos en la nube.