LAGOS DE DATOS EN AWS

CONTENIDO

LAGOS DE DATOS EN AWS 2

INTRODUCCIÓN 2

¿QUÉ ES UN LAGO DE DATOS? 2

SERVICIOS RELACIONADOS CON LOS LAGOS DE DATOS DE AWS 7

SERVICIOS UTILIZADOS EN LAGOS DE DATOS PARA ALMACENAMIENTO Y CATALOGACIÓN 8

AMAZON S3 8

AWS GLUE 10

SERVICIOS DE AWS UTILIZADOS PARA EL MOVIMIENTO DE DATOS 11

FAMILIA AWS KINESIS 12

KINESIS DATA STREAMS 13

KINESIS DATA FIREHOSE 14

AMAZON API GATEWAY 15

APP FLOW 16

SERVICIOS DE AWS UTILIZADOS PARA EL PROCESAMIENTO DE DATOS 17

AMAZON EMR 17

AWS GLUE 18

SERVICIOS DE AWS PARA ANÁLISIS 20

AMAZON ATHENA 20

KINESIS DATA ANALYTICS 21

AMAZON ELASTICSEARCH SERVICE 22

AMAZON OPENSEARCH SERVICE 22

AWS LAKEFORMATION 23

LAGOS DE DATOS EN AWS

INTRODUCCIÓN

Imagine que trabaja en una empresa emergente o startup como administrador de sistemas y que su trabajo consiste en asegurarse de que todo funcione sin problemas.
La carga de trabajo que suele manejar consiste en backend, ingestión de datos, y bases de datos con capas adicionales de procesamiento de datos. La empresa opera con equipos pequeños en los que normalmente una persona asume múltiples funciones por lo que es muy común ver a desarrolladores haciendo modelado de datos, jefes de proyecto desarrollando código, o DevOps gestionando bases de datos.
Recientemente, los clientes se están quejando de que el sistema va lento y tras investigar, usted se da cuenta de que la base de datos está llegando a su límite provocando un cuello de botella. Tras investigar, se da cuenta de que la misma base de datos se está utilizando para absolutamente todo, desde almacenar datos de streaming hasta ejecutar análisis y desde almacenar syslogs hasta datos de clientes. No tardó mucho en llegar a la conclusión de que la arquitectura de datos está funcionando con un enfoque de talla única y que es necesario descomponerla en componentes separados para desarrollar una estrategia de administración de datos más madura.
¿Le suena familiar? Porque a mí me suena muy familiar. Se trata de un escenario típico en el que un lago de datos sería de gran ayuda.
Así que se le ocurre un plan para salvar la situación. Dado que la carga de trabajo se ejecuta en la nube de AWS, ¿por qué no explorar los servicios relacionados con los datos de AWS para separar el almacenamiento, la ingestión de datos, el análisis, el análisis en tiempo real e incluso el aprendizaje automático, dividiendo esa monstruosa base de datos en componentes que hagan lo correcto para el trabajo.

Me gusta llamar a esto una estrategia de divide y vencerás. ¿No es un término genial? Y eso sería absolutamente mejor que utilizar un único servidor con mucho almacenamiento. Añadir un lago de datos a esta arquitectura podría ayudar a resolver muchos problemas utilizando la herramienta adecuada para el trabajo.

¿QUÉ ES UN LAGO DE DATOS?

Un lago de datos es un repositorio centralizado que le permite almacenar todos sus datos estructurados y no estructurados a cualquier escala. Puede almacenar sus datos tal cual, sin tener que estructurarlos primero, y ejecutar diferentes tipos de análisis, desde cuadros de mando y visualizaciones hasta procesamiento de big data, análisis en tiempo real y

aprendizaje automático para orientar mejores decisiones.

Aunque algunas soluciones de lagos de datos pueden sonar como una base de datos muy potente, ese es un malentendido común. Evitamos comparar los lagos de datos con las bases de datos porque los lagos de datos abarcan múltiples funciones en el espectro de los datos, como la ingestión de datos, el procesamiento, el aprendizaje automático, la visualización de datos y otros componentes.

Las principales razones para invertir en un lago de datos son: Aumentar la eficiencia operativa, hacer que los datos estén disponibles desde silos departamentales, reducir los costes transaccionales, y descargar capacidad de bases de datos y almacenes de datos.

Las bases de datos suelen tener sus mecanismos de almacenamiento y procesamiento unidos, lo que hace menos flexible escalar el almacenamiento sin procesamiento y viceversa.
Por otro lado, un lago de datos es un repositorio centralizado que debería permitirle almacenar de forma segura todos sus datos estructurados y no estructurados sin restricciones de escalado.
Una de las ventajas más significativas de un lago de datos es almacenar sus datos sin tener que pensar en su estructura. Y de ahí viene el nombre de lago, por ser información orgánica, como la naturaleza.

Permítame ponerle un ejemplo para ilustrar un escenario en el que un lago de datos es fundamental. Imagine que tiene un sitio web de comercio electrónico en el que le informan que las ventas han disminuido un 10% desde el viernes pasado.
Se da cuenta de que el viernes pasado, el equipo de front-end aplicó una implementación que cambió algunos elementos de la interfaz de usuario de pago. Si ingesta los datos del flujo de clics de los usuarios, como las coordenadas del ratón en su sitio web, puede obtener estos datos en bruto y trazar un mapa de calor con herramientas de visualización de datos. A un alto nivel, esto podría permitirle ver si los usuarios tienen dificultades para encontrar los botones en el front-end porque están intentando localizarlos tal y como estaban colocados en la antigua interfaz antes del despliegue.

Este es un ejemplo de datos sin procesar transformados en un insight y este es precisamente el tipo de cosas que nos permiten los lagos de datos. Los insights más significativos hoy en día se generan a partir de transacciones, registros web, streaming de clics, medios sociales y dispositivos del Internet de las Cosas o IoT.

Hagamos un paréntesis (Los **insights** son hallazgos significativos que permiten entender qué está ocurriendo en una organización y por qué. Se trata de conclusiones obtenidas a partir del análisis de datos que revelan patrones, tendencias o comportamientos clave. En otras palabras, los insights transforman datos en conocimiento útil para la toma de decisiones estratégicas.

Por ejemplo, un insight puede mostrar que cierto producto se vende más los fines de semana o que un tipo de cliente abandona un servicio tras una acción concreta. Este tipo de descubrimientos ayudan a mejorar procesos, anticipar problemas y generar ventajas competitivas.)

Como es de esperar, el volumen de datos que producen es bastante alto. No hace falta decir que son más adecuados para los servicios de almacenamiento que se dedican a almacenar datos. Al desacoplar el almacenamiento del procesamiento de datos, puede utilizar diferentes componentes de procesamiento de datos y visualización de datos que analizan los mismos datos y esa es otra ventaja de los lagos de datos sobre las bases de datos o los almacenes de datos.

Ahora que ya conoce la propuesta de valor de los lagos de datos, vamos a hablar más en profundidad de sus principales características.

El primer aspecto que me gustaría tratar sobre los lagos de datos es que deben ser **agnósticos** en cuanto a los datos. En otras palabras, los lagos de datos no deben limitarse a almacenar un único tipo de archivo o estructura de datos, como suele hacer una base de datos. Los lagos de datos eficientes le permiten almacenar todo tipo de datos, como imágenes, texto de datos en múltiples formatos, comprimidos o no, encriptados o no, audio, vídeo, archivos binarios, y todo lo demás. Ser agnóstico a los datos y almacenar datos en bruto le da la ventaja de utilizar una herramienta de procesamiento de datos más apropiada para generar perspectivas.

Permítame ponerle otro ejemplo. Piense en una plataforma de comercio electrónico a escala web con operaciones en todo el mundo. Con la información recopilada sobre los centros de cumplimiento de paquetes, los usuarios empresariales pueden querer utilizar esos datos para generar informes que conduzcan a percepciones sobre las ventas durante las temporadas de vacaciones, mientras que otros departamentos pueden estar interesados en utilizar esos datos para entrenar modelos de aprendizaje automático que sugieran mejoras en la logística y las operaciones de los centros de cumplimiento. Esos dos insights son de naturaleza diferente entre sí, pero pueden ser posibles si esos diferentes equipos tienen los datos disponibles y catalogados en un lago de datos que funcione eficientemente.
En pocas palabras, los lagos de datos permiten bucear en cualquier parte de los vastos datos recopilados para generar insights.

Solemos decir que otra característica de los lagos de datos maduros es el hecho de estar **a prueba de futuro**. Permítanme explicarlo mejor. Estar a prueba de futuro aquí suele indicar que puede que no tenga una pregunta de negocio hoy, pero si esa pregunta de negocio surge en el futuro y tiene datos sobre ese tema, la respuesta puede estar potencialmente ahí mismo. Con el uso de las herramientas de procesamiento y visualización de datos adecuadas, puede generar perspectivas que pueden ayudarle mucho.

Con una correcta ingestión de datos, catalogación, y procesamiento para mantenerlos organizados, será delicioso extraer perspectivas de ellos.
Hay dos tipos de procesamiento implicados en un lago de datos. El primero es el proceso realizado antes o durante la ingesta de datos. El segundo es el proceso realizado después de que los datos hayan sido almacenados. Este proceso incluye, entre otros, la limpieza, la agregación, el enriquecimiento, la fusión con otros conjuntos de datos y mucho más.

Muy bien, hablemos más en profundidad sobre los cuatro componentes principales que le gustaría tener en su arquitectura de lago de datos: Ingesta y almacenamiento, catálogo y búsqueda, procesar y servir, proteger y asegurar.

La ingesta y el almacenamiento: Un lago de datos no es un lago de datos maduro sin los mecanismos de ingesta de datos adecuados. Dado que los lagos de datos son agnósticos en cuanto a los datos, esto puede ser un reto porque se necesitan diferentes tecnologías para ingerir diferentes datos en una ubicación central.
Permítanme darles algunos ejemplos para ilustrar lo que quiero decir. Imagine una empresa con una flota de 100 camiones equipados con dispositivos IoT, digamos que los dispositivos están equipados con antenas GPS y conexiones móviles que proporcionan las coordenadas del camión cada segundo. Cuando se envían estos datos, el sistema debe proporcionar la ubicación del camión en tiempo real a sus usuarios.
Si hace los cálculos, con 100 camiones proporcionando datos cada segundo, tendrá 6.000 puntos de datos por minuto, 360.000 puntos de datos cada hora, y mucho más de un millón de puntos de datos sólo durante el horario laboral.

Este requisito puede necesitar soluciones de ingestión de datos y almacenamiento que funcionen con una latencia mínima a gran escala, lo que claramente supone un reto, especialmente si no se utiliza el enfoque adecuado.

En esta carrera por la menor latencia, una mejor capa de ingestión probablemente utilice tecnologías de streaming de datos, como los servicios de la familia Amazon Kinesis o Amazon Managed Streaming para Apache Kafka.
Tal vez podríamos utilizar un mecanismo de ingestión de datos diferente si los requisitos fueran distintos en este escenario. Si no necesitáramos proporcionar información casi en tiempo real a los usuarios, podríamos pensar en utilizar un mecanismo de ingestión que consuma datos por lotes y no en streaming.

El catálogo y la búsqueda de datos: Los lagos de datos maduros proporcionan mecanismos de indexación y búsqueda eficientes para descubrir rápidamente qué datos están almacenados y dónde.
¿Ha oído ya el término no deje que su lago de datos se convierta en un pantano de datos?
El término pantano de datos es aquí una forma informal de representar a los lagos de datos que están desorganizados en términos de catálogo y búsqueda de datos.
Los lagos de datos pueden y deben alcanzar un alto nivel de organización y catálogo con la ayuda de bases de datos. Independientemente de si la base de datos es SQL o NoSQL, es muy importante disponer de una forma rápida y segura de encontrar sus datos cuando esté buscando algo.

La capa de procesamiento: Algunas personas de la comunidad de datos abogan por utilizar Hadoop como solución integral del lago de datos. Utilizar Hadoop de esa manera puede sonar perfecto porque dispone de almacenamiento de datos y, al mismo tiempo, está preparado en términos de procesamiento de datos.
Apache Hadoop es una tecnología de big data muy popular que le ofrece la posibilidad de almacenar y procesar datos utilizando servidores configurados con software de código abierto. Dado que el clúster Hadoop tiene el procesamiento y el almacenamiento estrechamente acoplados, cuando asigna servidores para utilizar Hadoop, acaba pagando tanto por el almacenamiento como por el procesamiento.
Uno de los principales componentes de la computación en nube es pagar por lo que se usa y nada más. Así que, si sólo quiere usar Hadoop para almacenamiento, puede estar pagando por potencia de procesamiento sin usarla. Eso no significa que Hadoop no use lagos de datos. Desempeñan un gran papel y los lagos de datos no existirían sin él, pero tiene más sentido usar Hadoop sólo cuando necesitamos procesar algo. Por eso un lago de datos nativo de la nube utiliza servicios de almacenamiento dedicados que sólo le cobran por el almacenamiento y nada más.
Puede utilizar servicios de almacenamiento en la nube como Amazon S3, que suele ser más barato y más duradero porque no hay procesamiento de por medio.

Normalmente, en los lagos de datos, cuando se necesita procesar algo, se puede poner en marcha lo que llamamos un clúster Hadoop transitorio, hacer el procesamiento, almacenar los datos de nuevo en S3, y luego apagar el clúster.
Además de eso, separar la computación del almacenamiento le da otro beneficio, que es la capacidad de utilizar diferentes capas de computación y almacenamiento utilizando la herramienta adecuada para el trabajo mientras se optimiza tanto el coste como el rendimiento.
AWS tiene un servicio llamado AWS Glue, que ejecuta trabajos Hadoop bajo demanda donde sólo se paga cuando hay un trabajo en ejecución.

La protección y la seguridad: Un lago de datos maduro debería proporcionar todos los componentes mencionados hasta ahora de forma segura con mecanismos de permisos configurables que impidan a los usuarios no autorizados acceder a los datos.
El uso de los servicios administrados de AWS le ofrece la posibilidad de administrar aspectos como la retención de datos, el cifrado, las listas de control de acceso y normas de gobernanza refinadas.

SERVICIOS RELACIONADOS CON LOS LAGOS DE DATOS DE AWS

Piense en los servicios que componen su lago de datos como pertenecientes a una de estas tres categorías: Almacenamiento y catalogación de datos, movimiento de datos y, análisis y procesamiento.

La primera categoría son los servicios de AWS utilizados para **el almacenamiento y la catalogación de datos**.

Un lago de datos tiene unos cuantos componentes clave:

- Almacena y asegura los datos a una escala ilimitada.
- Permite almacenar conjuntamente datos estructurados y no estructurados.
- Cataloga e indexa los datos sin necesidad de moverlos.
- Conecta los datos con servicios y herramientas para su análisis y procesamiento.

Entonces, ¿qué servicios de AWS puede utilizar para habilitar estos factores clave de un lago de datos? Lo cubriremos con los servicios de AWS utilizados para el almacenamiento y la catalogación de datos. Esta categoría se centra en los servicios utilizados para construir el lago de datos en sí, no los servicios utilizados para poblar el lago de datos, o analizar los datos en el lago de datos.

La siguiente categoría de servicios que cubriremos son los servicios de AWS utilizados para **el movimiento de datos**. Una vez que sepa qué servicios va a utilizar para construir su lago de datos, ¿cómo va a ingerir datos en ese lago de datos? Bueno, tiene que mover los datos

desde su origen o fuente al lago de datos para que luego puedan ser indexados y estén disponibles para su procesamiento y análisis.
Existen múltiples servicios de AWS que soportan el movimiento de datos en un sentido general y los servicios que utilice dependen totalmente de su caso de uso.

La última categoría de servicios de AWS que cubriremos son los servicios de AWS utilizados para **el análisis y el procesamiento**. Teniendo una idea de cómo se mueven los datos a su lago de datos, y qué servicios se utilizan para indexarlos y catalogarlos adecuadamente, la pregunta entonces es: ¿cuándo y qué servicios puede utilizar para procesar y analizar los datos?
Puede que desee ejecutar consultas SQL en los datos, tal vez unir varios conjuntos de datos para introducirlos en un cuadro de mando para su visualización, o incluso utilizar los datos para generar cosas como informes empresariales.

Cubriremos varios servicios de AWS que puede utilizar en esta categoría, y al igual que en la categoría de movimiento de datos, los servicios de AWS que utilice dependen en gran medida del caso de uso.

Cuando observe una arquitectura similar a la de datos, recordar estas tres agrupaciones distintas de servicios puede ayudarle a dividirla en un concepto más manejable.
En primer lugar, tiene el aspecto de almacenamiento y catalogación. En segundo lugar, tiene el aspecto de movimiento de datos. Y, en tercer lugar, está el aspecto de análisis y procesamiento.

SERVICIOS UTILIZADOS EN LAGOS DE DATOS PARA ALMACENAMIENTO Y CATALOGACIÓN

AMAZON S3: Como estamos hablando de lagos de datos, sabe que va a tener muchos datos. Podría tener miles de terabytes de datos que necesita almacenar y sabe que necesitará utilizar servicios que se amplíen a medida que crezca su conjunto de datos, así como que le permitan almacenar conjuntamente datos no estructurados y estructurados.
Se requiere un servicio que permita trabajar con este modelo de esquema sobre lectura a la vez que tenga incorporadas funciones de escalado que faciliten el alojamiento de un lago de datos. S3 y S3 Glacier son los servicios de AWS preferidos para la capa de almacenamiento de su lago de datos.

La primera razón es que puede almacenar cualquier tipo de archivo que desee.
La capa de almacenamiento debe ser agnóstica a los datos y este es un elemento clave de un lago de datos. Los datos no deben existir en silos donde los datos de un tipo se almacenan por separado de los datos de otro tipo. Todo debe estar en un lugar centralizado.
S3 tiene el concepto de buckets que le permiten almacenar contenidos de cualquier tipo juntos sin límite en el tamaño total del bucket.

La segunda razón es el escalado. A medida que necesite almacenar más datos en su lago de datos, S3 simplemente se encarga de ello, no hay necesidad de configurar ningún tipo de escalado con S3.

Otra característica que hace de S3 un servicio muy querido para los lagos de datos es su impresionante durabilidad. S3 está diseñado para proporcionar una durabilidad del 99.999999999% de durabilidad para sus objetos a lo largo de un año determinado.
Ahora bien, eso son muchos nueves. Lo que esto significa realmente en un sentido práctico es que, si sube un objeto a S3, la probabilidad de que ese objeto se corrompa o se pierda con el tiempo es increíblemente baja. Eso lo convierte en un gran candidato para los lagos de datos porque usted recopilará los datos bajo el supuesto de que, aunque no se estén utilizando actualmente, se utilizarán en el futuro.

Otro componente clave de un lago de datos es que los datos sean accesibles para que las herramientas y los servicios procesen y analicen los datos. La mayoría de las soluciones de AWS y comerciales ya saben cómo trabajar con S3 como capa de datos.

Además de que S3 es escalable, duradero y ofrece integraciones para el análisis, también tiene algunas características específicas que puede utilizar para ayudar a reducir el coste de funcionamiento de su lago de datos.
S3 ofrece diferentes niveles de almacenamiento que le permiten clasificar sus datos en diferentes niveles de coste en función de la frecuencia con la que se accederá a ellos.
La forma en que se desglosa es, si se accede a los datos con frecuencia, puede utilizar un nivel que le cobrará menos por las solicitudes realizadas para acceder a los datos, pero le cobrará más por el almacenamiento de esos datos.
Si se accede a los datos con poca frecuencia, elija una clase de almacenamiento que cobre más por las peticiones, pero menos por el almacenamiento.

También puede aprovechar Amazon S3 Glacier y S3 Glacier Deep Archive. Esto es para objetos a los que no se accede con regularidad y que, por lo tanto, pueden archivarse.
Los datos almacenados con Glacier incurren en el menor coste de almacenamiento disponible y, aunque proporciona un menor coste por gigabyte, existen tarifas asociadas al tiempo de recuperación. Esta es una buena opción para almacenar datos que actualmente no tienen un caso de uso conocido, pero que podría utilizar en el futuro. También es bueno utilizarlo para datos históricos que ya no se utilizan, pero que desea conservar por diversas razones.

En resumen, Amazon S3 es la capa de almacenamiento de elección para los lagos de datos alojados en AWS.

Ahora vamos a hablar brevemente sobre la catalogación e indexación de datos almacenados en S3 para su lago de datos.

CATÁLOGO DE DATOS DE AWS GLUE: Uno de los principales problemas que tienen las organizaciones cuando intentan crear y operar un lago de datos es que pueden encontrarse con que tienen una gran cantidad de activos en bruto, pero los usuarios del lago de datos no están realmente seguros de qué son esos datos o incluso de cómo averiguar qué datos existen para que puedan comenzar a analizarlos y procesarlos.
Además, los datos se transformarán con el tiempo. Hacer un seguimiento de los cambios en los formatos de los datos y las versiones de los datos puede resultar confuso para los usuarios cuando no se gestiona adecuadamente. No están seguros de si los datos que necesitan están en el lago de datos o no.
Esto significa que los datos, aunque existen, no son muy útiles. Están desorganizados. Son oscuros y turbios. No son visibles. Son más bien un pantano de datos. Cuando los datos no se convierten fácilmente en conocimiento, puede que tenga un pantano de datos.

Unos metadatos adecuados son el primer paso. Los metadatos son datos sobre los datos. Entonces, ¿por qué son útiles los metadatos? Consideremos una biblioteca. Cuando entra en una biblioteca, hay miles de libros. ¿Cómo sabe dónde encontrar el libro que busca? Pues bien, las bibliotecas disponen de sistemas que le ayudan a buscar el libro que necesita a través de sus metadatos, como el título, el número ISBN (International Standard Book Number o Número Estándar Internacional de Libros) o el autor.
Usted necesita una forma similar de catalogar sus datos en su lago de datos. Y no busque más allá del servicio AWS Glue.

AWS GLUE: Es un servicio ETL (extraer, transformar y cargar) totalmente administrado que hace que sea sencillo y rentable categorizar sus datos, limpiarlos, enriquecerlos y moverlos de manera fiable entre varios almacenes y flujos de datos. AWS Glue consta de un repositorio central de metadatos conocido como Catálogo de datos de AWS Glue, un motor ETL que genera automáticamente código Python o Scala, y un programador flexible que se encarga de la resolución de dependencias, la monitorización de trabajos y los reintentos. AWS Glue no tiene servidor, por lo que no hay infraestructura que configurar o administrar.

El **catálogo de datos** de AWS Glue es su almacén de metadatos persistente. Es un servicio administrado que le permite almacenar, anotar y compartir metadatos en la nube de AWS del mismo modo que lo haría en un almacén de metadatos de Apache Hive.
Consta de tablas, que son la definición de metadatos que representa sus datos. Una tabla consta de un esquema y las tablas se organizan en grupos lógicos denominados bases de datos.

AWS Glue también le permite configurar **rastreadores** que pueden escanear datos en todo tipo de repositorios, clasificarlos, extraer información de esquemas de ellos y almacenar los metadatos automáticamente en el catálogo de datos de AWS Glue. A continuación, el catálogo de datos de AWS Glue puede utilizarse para guiar las operaciones ETL.

Se utilizan los rastreadores o Glue crawler para poblar el catálogo de datos de AWS Glue con tablas. Un Glue crawler se activa para clasificar sus datos en S3 y llama a la lógica clasificadora para inferir el esquema, el formato y el tipo de datos.
Construirán un catálogo de datos utilizando clasificadores existentes para formatos de activos populares, como JSON por ejemplo, pero también tiene la posibilidad de añadir sus propios clasificadores o elegir clasificadores de la comunidad de AWS Glue. Esto es útil cuando se trata de reconocer y catalogar otros formatos de datos que no son compatibles con los rastreadores incorporados.
Los metadatos generados por los rastreadores se utilizan entonces para ayudarle a comprender sus datos y se utilizan en el proceso de autoría de sus trabajos ETL.

AWS Glue elimina la necesidad de crear y definir esquemas manualmente. Incluso puede configurar su rastreador para que actualice el catálogo de datos si el esquema de los datos cambia o se elimina, así como comparar versiones de sus tablas para realizar un seguimiento de los cambios de los datos a lo largo del tiempo.
Una vez que añada sus definiciones de tablas al catálogo de datos Glue, estarán disponibles para los trabajos ETL y también fácilmente disponibles para realizar consultas en otros servicios de procesamiento de AWS. Este es otro componente principal para mantener un lago de datos bonito y valioso.

SERVICIOS DE AWS UTILIZADOS PARA EL MOVIMIENTO DE DATOS

Los lagos de datos permiten importar cualquier cantidad de datos que puedan llegar en tiempo real. Los datos se recogen de múltiples fuentes y se trasladan al lago de datos en su formato original. Este proceso le permite escalar a datos de cualquier tamaño, al tiempo que ahorra tiempo de definición de estructuras de datos, esquemas y transformaciones.

Piense en un lago real. ¿Cómo llegó el agua a ese lago? O, dicho de otro modo, ¿cómo se formó ese lago? ¿Está alimentado por una pequeña pero constante corriente de agua que siempre fluye hacia dentro? ¿Está alimentado por una gran cascada que vierte miles de galones de agua en el lago por minuto? O quizás se formó por agua que solían ser glaciares hace miles de años, pero ahora sólo se llena con lluvias ocasionales, o quizás es una combinación de fuentes la que llena el lago.
Tomemos esta idea de cómo obtienen su agua los lagos literales y apliquémosla al concepto de un lago de datos.
Es probable que los datos de un lago de datos procedan de múltiples fuentes, y la forma de mover o ingerir esos datos dependerá de la fuente y del tipo de datos que esté ingiriendo.
Considere cómo un arroyo alimenta un lago real. Hay una pequeña cantidad de agua que vierte constantemente en el lago con un flujo constante. Ahora, piense en su lago de datos. Tal vez tenga una fuente de datos en la que tenga que ingerir constantemente pequeños

fragmentos de datos para llenar el lago de datos. Por ejemplo, imagine que tiene agua pasando por una tubería, y que coloca un sensor en la tubería, y este sensor mide la temperatura del agua y envía los datos para que sean ingeridos y luego procesados.
Este es un ejemplo de ingestión de datos en tiempo real o ingestión de flujos de datos en movimiento.

FAMILIA AWS KINESIS: Amazon Kinesis facilita la recopilación, el procesamiento y el análisis de datos de streaming en tiempo real para que pueda obtener perspectivas oportunas y reaccionar con rapidez ante la nueva información. Amazon Kinesis ofrece capacidades clave para procesar de manera rentable los datos de streaming a cualquier escala, junto con la flexibilidad para elegir las herramientas que mejor se adapten a los requisitos de su aplicación. Con Amazon Kinesis, puede ingerir datos en tiempo real como vídeo, audio, registros de aplicaciones, secuencias de clics de sitios web y datos telemétricos de IoT para el aprendizaje automático, el análisis y otras aplicaciones. Amazon Kinesis le permite procesar y analizar los datos a medida que llegan y responder al instante en lugar de tener que esperar a que se recopilen todos los datos para poder comenzar el procesamiento.

Hay tres cosas importantes que debemos saber sobre Kinesis y que observamos en el siguiente diagrama:

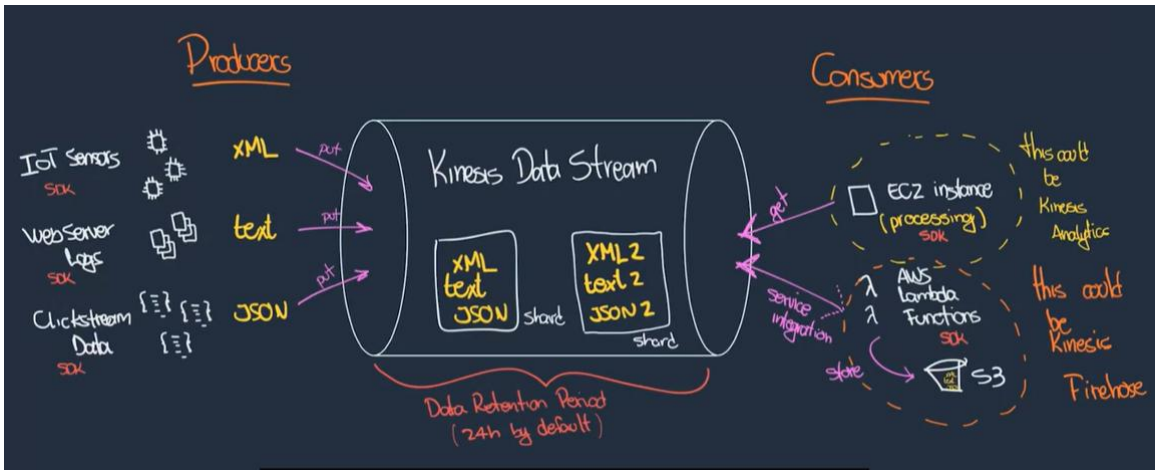

1. Kinesis es agnóstico en cuanto a datos. Puede verlo por los diferentes productores de datos que envían datos al mismo flujo de datos de Kinesis. Puede enviar datos JSON o XML, estructurados o no estructurados. Si los configura correctamente mediante el SDK de Kinesis, Kinesis los almacenará.
   Puede que desee crear un flujo de datos de Kinesis por tipo de datos o concentrar los datos en el mismo flujo de datos de Kinesis. La forma en que diseñe su arquitectura depende de usted.

2. Los datos permanecen en los flujos de datos de Kinesis, independientemente de si se han consumido o no. Los datos permanecen allí hasta que caducan según lo que llamamos período de retención de datos. Ese periodo de retención de datos es de 24 horas por defecto, pero puede ampliarlo realizando llamadas a la API de servicio, lo que también aumentaría el coste por hora del flujo de datos de Kinesis.
   Conservar los datos en Kinesis es valioso porque varios consumidores pueden consumir los mismos datos al mismo tiempo. Además de eso, permite volver a reproducir el consumo de datos en caso de fallos del consumidor de datos.

3. Observe en el diagrama la dirección de las flechas en el lado del consumidor de datos, en el lado derecho del diagrama.
   En algunos diagramas, es posible que vea flechas de izquierda a derecha porque esa es la dirección general del flujo de datos. Pero creo que es más preciso técnicamente cuando se apuntan flechas de los consumidores a Kinesis y no de Kinesis a los consumidores y he aquí por qué. Kinesis no funciona como un mecanismo de entrega basado en push.
   Si un consumidor quiere consumir datos de Kinesis, debe iniciar una conexión utilizando la biblioteca de clientes de Kinesis, disponible para los lenguajes de programación más populares.

Puede utilizar un servicio de la familia Kinesis para la ingestión de datos en tiempo real. Kinesis dispone de varios servicios de AWS que le permiten ingerir flujos de datos de varios tipos y analizar esos datos en tiempo real, trasladando los datos a AWS de forma segura y escalable.

KINESIS DATA STREAMS: Amazon Kinesis Data Streams (KDS) es un servicio de streaming de datos en tiempo real masivamente escalable y duradero. KDS puede capturar continuamente gigabytes de datos por segundo de cientos de miles de fuentes, como flujos de clics de sitios web, flujos de eventos de bases de datos, transacciones financieras, feeds de medios sociales, registros de TI y eventos de seguimiento de ubicación. Los datos recopilados están disponibles en milisegundos para permitir casos de uso de análisis en tiempo real como cuadros de mando en tiempo real, detección de anomalías en tiempo real, precios dinámicos, etc.

Kinesis Data Streams se utiliza para recopilar datos de diversas fuentes, y a continuación puede crear aplicaciones Kinesis para procesar continuamente los datos, generar métricas, alimentar cuadros de mando en directo, o enviar datos agregados a almacenes como Amazon S3.

Para utilizar Kinesis Data Streams, tiene que utilizar el kit de desarrollo de software de AWS o SDK para Kinesis, y procesar los datos entrantes, que se organizan en shards. Usted es responsable de escalar estos shards dentro y fuera, según sea necesario. Los datos

almacenados en los shards pueden ser procesados por uno o múltiples consumidores, todos ellos utilizando el SDK.

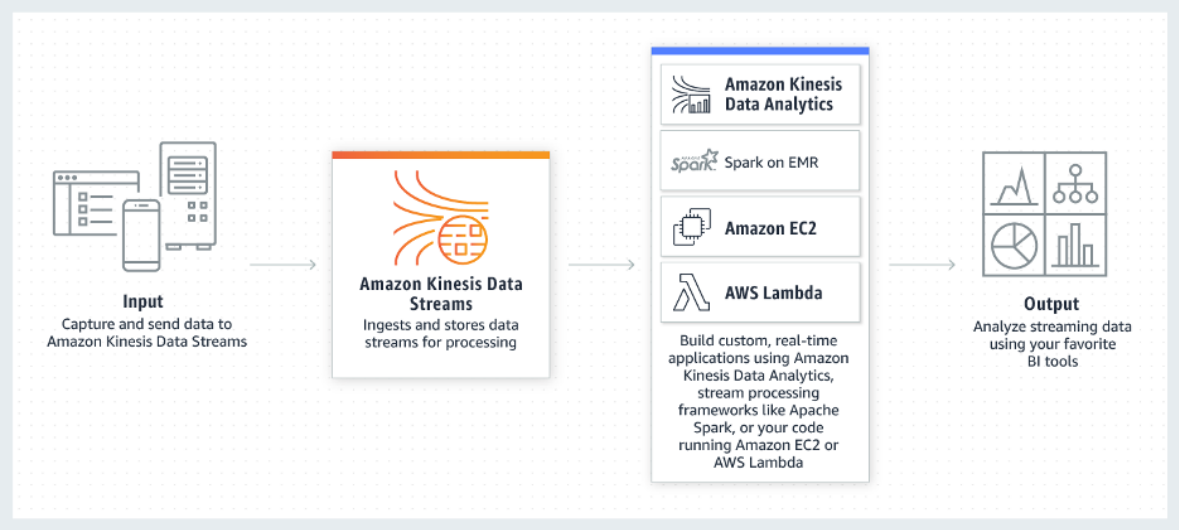

KINESIS DATA FIREHOSE: Si no es un tipo de desarrollador y no quiere preocuparse por utilizar el SDK o pensar qué son los shards o cómo gestionarlos, puede utilizar en su lugar otro servicio de la familia Kinesis, llamado Kinesis Firehose.

Kinesis Data Firehose es la forma más sencilla de cargar de manera fiable datos de streaming en lagos de datos, almacenes de datos y servicios de análisis. Puede capturar, transformar y entregar datos de streaming a Amazon S3, Amazon Redshift, Amazon Elasticsearch Service, puntos finales HTTP genéricos y proveedores de servicios como Datadog, New Relic, MongoDB y Splunk. Se trata de un servicio totalmente gestionado que se escala automáticamente para adaptarse al rendimiento de sus datos y que no requiere una administración continua. También puede procesar por lotes, comprimir, transformar y cifrar sus flujos de datos antes de cargarlos, lo que minimiza la cantidad de almacenamiento utilizado y aumenta la seguridad.

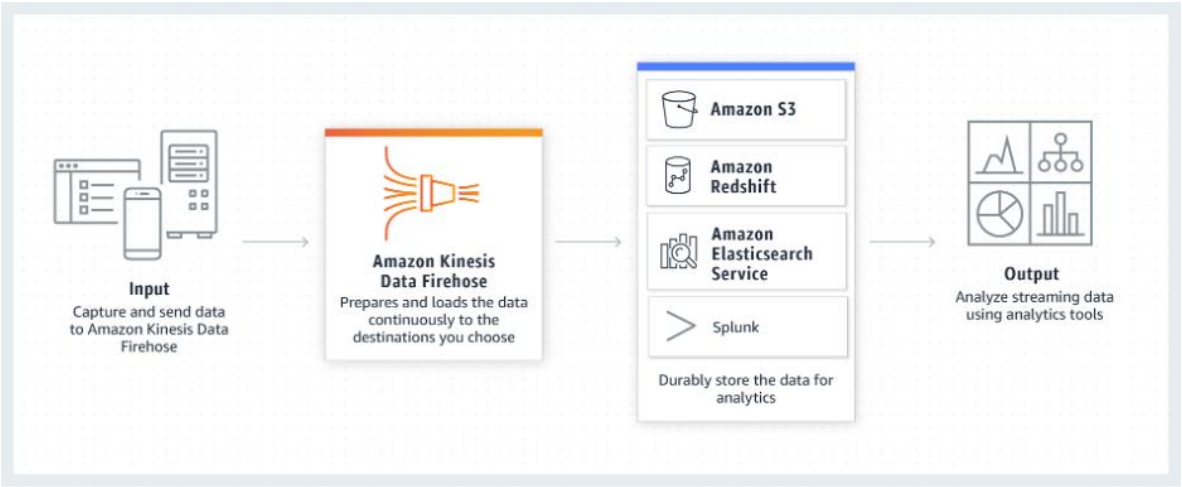

Ahora bien, no todos los datos de su lago de datos estarán ahí a partir de la ingestión de datos en tiempo real. Digamos que le gustaría ingerir datos de forma reposada. Por ejemplo, cuando trabaje con dispositivos IoT, probablemente querrá que el dispositivo transmita datos que usted pueda recopilar. Los dispositivos IoT suelen ser microcontroladores con capacidades de hardware limitadas. Dadas estas limitaciones, utilizar un SDK como el SDK de Kinesis podría funcionar, pero podría ser más sencillo utilizar llamadas HTTP estándar.
Las bibliotecas HTTP son ligeras y pueden cargarse fácilmente.
Entonces, ¿qué servicio de AWS puede utilizar para la ingestión de datos que permita una llamada HTTP o incluso WebSockets? No busque más, Amazon API Gateway.

AMAZON API GATEWAY: Amazon API Gateway es un servicio totalmente administrado que facilita la creación, la publicación y el mantenimiento de API seguras a escala. Las API son la puerta de entrada a las aplicaciones y servicios backend. API Gateway se encarga de todas las tareas relacionadas con la aceptación y el procesamiento de hasta cientos de miles de llamadas concurrentes a las API, incluida la gestión del tráfico, la autorización y el control del acceso, el estrangulamiento, la monitorización y la gestión de la versión de las API.

Es un servicio que le permite alojar APIs que actúan como puerta de entrada o interfaz a un backend. Este backend podría ser una aplicación que se ejecuta en una instancia EC2 o una función AWS Lambda, o incluso otro servicio de AWS como Kinesis. Al alojar una API restful con API Gateway, puede ingerir datos en su lago de datos simplemente enviando llamadas HTTP desde su fuente de datos con los datos publicados en la carga útil, sin necesidad de utilizar ningún SDK específico ni librerías pesadas.
API Gateway puede ser una alternativa más sencilla para la ingesta de datos, pero no ofrece la misma profundidad de características para la ingesta de datos de tipo flujo en su lago de datos con un servicio como Kinesis.

Lo que elija utilizar depende realmente de su caso de uso. A menudo hay casos de uso en los que necesita ingerir datos de fuentes de terceros, fuentes de terceros que usted no gestiona o sobre las que no tiene control. Dependiendo de cuáles sean sus objetivos, los datos de terceros podrían enriquecer los datos que ya ha recopilado. Por ejemplo, digamos que usted es una empresa que crea software para servicios sanitarios. Puede que le interese recopilar datos anonimizados de proveedores sanitarios o procesadores de datos que pueda almacenar con sus propios datos para obtener información. En lugar de intentar conservar estos datos usted mismo, utilizando medios físicos o gestionando credenciales FTP, o integrándose con diferentes API, considere la posibilidad de utilizar el servicio AWS Data Exchange. Data Exchange ofrece una interfaz a cientos de productos comerciales de proveedores de datos de muchos sectores, como los servicios financieros o la sanidad u otros. Puede utilizar las API de Data Exchange para extraer y entregar de forma segura los datos relevantes en su destino S3.

Ahora bien, ¿qué ocurre con los datos que se generan mediante el uso de un software de terceros, pero son datos que sí son de su propiedad? Por ejemplo, los datos que proceden de herramientas como Salesforce o Google Analytics. Podría pensar que necesita escribir sus propios conectores a estos servicios, para conseguir que los datos proporcionados por esta aplicación SAS entren en su lago de datos. La buena noticia es que el servicio AppFlow puede encargarse de gran parte de esto por usted.

APP FLOW: Realiza la recopilación de datos y la transferencia segura a su lago de datos por usted, sin necesidad de que escriba su propio código de conector personalizado. Puede ejecutar flujos de transferencia de datos bajo demanda, de forma programada o después de un evento. Puede analizar rápidamente estos datos utilizando servicios como Amazon Athena para unirlos con otros múltiples conjuntos de datos ya almacenados en S3. También puede utilizar conjuntos de datos precurados a través del registro de datos abiertos en AWS, que facilita la búsqueda de conjuntos de datos puestos a disposición del público a través de los servicios de AWS. Puede consumir los datos que se alojan a través de este programa, e incluso puede solicitar compartir sus propios conjuntos de datos. Compartir datos en la nube permite a los usuarios centrarse en el análisis y en la obtención de perspectivas.

Para terminar, al igual que los lagos reales que se forman de varias maneras o se forman de una combinación de maneras, su lago de datos en AWS se formará con datos procedentes de varios lugares, y las herramientas que utilice para la ingestión de datos también variarán. Puede utilizar un servicio de la familia Kinesis para la ingestión de datos en tiempo real, Amazon API Gateway para la ingestión de datos restful, AppFlow para la ingestión de datos desde aplicaciones SAS, Data Exchange, o el Registro de Datos Abiertos para conjuntos de datos públicos que desee ingestar en su lago de datos.

SERVICIOS DE AWS UTILIZADOS PARA EL PROCESAMIENTO DE DATOS

Ya sabemos qué servicios se utilizan generalmente para el almacenamiento y el movimiento de datos. ¿Pero qué hay del procesamiento y el análisis de datos? Sin duda queremos utilizar realmente los datos una vez que hayan sido ingestados y almacenados.
Ahora, hablaremos de qué servicios utilizar para el procesamiento y el análisis a un alto nivel.

En primer lugar, hablemos de la idea de transformar los datos. Es habitual que necesite retocar los datos de su lago de datos antes de analizarlos, porque puede descubrir que los datos que está ingiriendo no están en un formato muy útil, o quizá los datos incluyan cosas como saltos de línea que su herramienta no puede manejar, o los datos están sucios y llenos de errores como duplicados o campos que faltan.
Es posible que desee procesar sus datos por lotes, o a medida que los datos llegan de la ingestión de flujos, en directo. Depende del caso de uso.

Centrémonos primero en la idea de procesar los datos por lotes. Para procesar los datos por lotes, puede crear scripts para corregir errores, reformatear, o procesar de otro modo los datos después de que se hayan cargado en su lago de datos. Es habitual utilizar un clúster Hadoop para este procesamiento de datos. Apache Hadoop es un marco de trabajo de código abierto que se utiliza para almacenar de forma eficiente y procesar grandes conjuntos de datos cuyo tamaño oscila entre gigabytes y petabytes de datos. En lugar de utilizar un ordenador grande y potente para almacenar y procesar los datos, Hadoop le permite agrupar varios ordenadores juntos para analizar conjuntos de datos masivos en paralelo y con rapidez.
Supongamos que ya dispone de un clúster Hadoop, y que lo ha estado utilizando en sus instalaciones y ahora quiere pasar a utilizar AWS utilizando las mismas herramientas para minimizar la refactorización. En este caso, puede utilizar Amazon EMR.

AMAZON EMR: Es una plataforma de clúster administrada que le permite procesar y analizar los datos de su lago de datos.
A diferencia de las limitaciones de infraestructura de los clústeres on-premise, EMR desacopla la informática y el almacenamiento, ofreciéndole la posibilidad de escalar cada uno de forma independiente utilizando S3 como capa de almacenamiento.
Amazon EMR es magnífico para procesar datos por lotes, porque le permite procesar cantidades masivas de datos de forma eficiente. Y es probable que trabaje con cantidades masivas de datos en su lago de datos. Con EMR, puede crear clústeres de larga duración o transitorios. La ventaja de un clúster transitorio es que puede poner en marcha un clúster, y luego se apaga cuando finaliza su trabajo de procesamiento, pagando sólo por lo que utiliza. Por el contrario, los clústeres persistentes siguen funcionando una vez finalizado el procesamiento de los datos. Si determina que su clúster estará inactivo la mayor parte del tiempo, es mejor utilizar clústeres transitorios. Por ejemplo, si tiene un trabajo de

procesamiento por lotes que extrae sus registros web de Amazon S3 y procesa los datos una vez por hora, probablemente será más rentable utilizar clústeres transitorios para procesar sus datos y luego apagar los nodos cuando el procesamiento haya finalizado.

Así que, aunque EMR gestiona el clúster Hadoop por usted, ¿no sería realmente agradable si pudiera simplemente ejecutar sus trabajos de procesamiento sin preocuparse de la configuración y la gestión de un clúster? Aquí es donde el servicio AWS Glue puede ser útil.

AWS GLUE: Ya conoce el catálogo de datos AWS Glue, pero tiene otras características que puede utilizar en su lago de datos. Anteriormente mencionamos que Glue es una herramienta ETL administrada que facilita la categorización de sus datos, transformarlos, enriquecerlos y moverlos de forma fiable entre varias fuentes y flujos de datos.
Ya hablamos de los rastreadores y que puede utilizar la salida creada a partir de ellos para ejecutar sus trabajos ETL. Pero hablemos más sobre lo que esto significa realmente.

AWS Glue tiene un concepto llamado trabajos (Jobs). Los trabajos son la lógica empresarial que se requiere para realizar el trabajo de procesamiento de datos, el tipo de trabajo que haría con un clúster de Amazon EMR o Hadoop. Con los trabajos de Glue, en lugar de crear un clúster en el que ejecutar su lógica de procesamiento, en su lugar proporciona un conjunto de configuraciones.

Un trabajo es la lógica empresarial que realiza el trabajo de extracción, transformación y carga (ETL) en AWS Glue. Cuando inicia un trabajo, AWS Glue ejecuta un script que extrae datos de las fuentes, transforma los datos y los carga en los destinos. Puede crear trabajos en la sección ETL de la consola de AWS Glue.

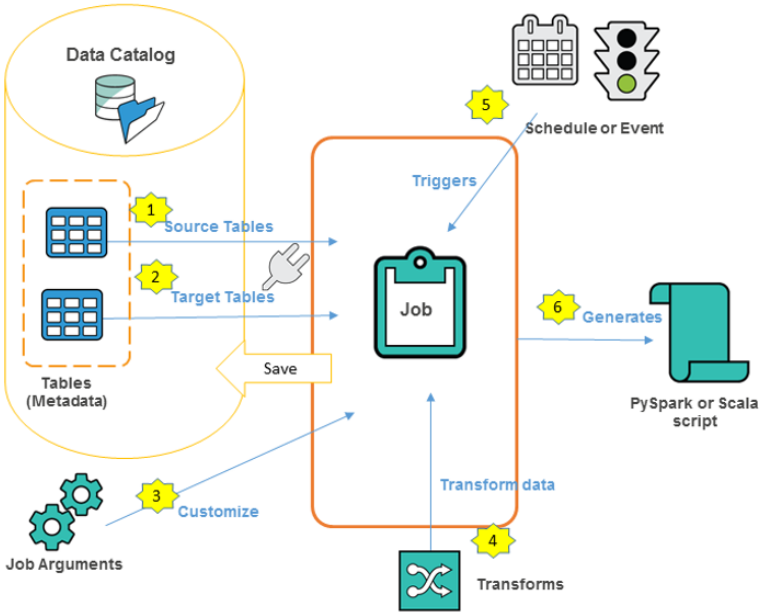

Un trabajo se compone de fuentes de datos y destinos de datos, que proceden de las tablas creadas en el catálogo de datos de AWS Glue. También tiene un script de transformación, así como otras personalizaciones que usted proporcione. Este trabajo se ejecuta según una programación o se activa por un evento. El trabajo se ejecuta y transforma o mueve sus datos y Glue hará toda la orquestación y la gestión de la infraestructura subyacente que se necesita para ejecutar su lógica de procesamiento de datos. Piense en ello como un Hadoop sin servidor.

Amazon EMR le dará un mayor control sobre todo el proceso, pero Glue jobs es una herramienta muy conveniente.

Ahora, imagine que está recopilando datos en tiempo real utilizando uno de los servicios de Kinesis, ya sea Kinesis Data Streams o Kinesis Firehose.

Los datos que está recopilando son datos sin procesar, y puede que no estén en el mejor formato para analizarlos. En este escenario, desea transformar los datos a medida que llegan, en lugar de ejecutar trabajos de procesamiento o procesarlos por lotes. ¿Qué opciones existen para este caso de uso? El primer servicio que le viene a la mente es AWS Lambda.

AWS LAMBDA: AWS Lambda es un servicio informático que le permite ejecutar código sin aprovisionar ni administrar servidores. AWS Lambda ejecuta su código solo cuando es necesario y escala automáticamente, desde unas pocas solicitudes al día hasta miles por segundo. Solo paga por el tiempo de cómputo que consume - no hay cargos cuando su código no se está ejecutando. Con AWS Lambda, puede ejecutar código para prácticamente cualquier tipo de aplicación o servicio backend - todo ello con cero administración. AWS Lambda ejecuta su código en una infraestructura informática de alta disponibilidad y realiza toda la administración de los recursos informáticos, incluido el mantenimiento del servidor y del sistema operativo, el aprovisionamiento de capacidad y el escalado automático, la monitorización del código y el registro.

Al utilizar AWS Lambda, solo es responsable de su código. AWS Lambda administra la flota informática que ofrece un equilibrio de memoria, CPU, red y otros recursos. Esto puede ser útil al procesar datos entrantes para su lago de datos alojado en AWS.

Es un servicio informático sin servidor que se ejecuta bajo demanda en función de activadores.

KINESIS DATA STREAMS: Es un activador disponible para sus funciones Lambda. Esto le permite preprocesar los datos antes de enviarlos a su destino final.

SERVICIOS DE AWS PARA ANÁLISIS

Hablemos ahora de algunas herramientas analíticas que puede utilizar una vez que sus datos estén procesados y en un formato listo para ser consumido.
Puede utilizar varias herramientas para analizar datos dependiendo de los propios datos y de los resultados que desee obtener.

Considere este ejemplo. Los datos que desea analizar están en formato CSV y se encuentran en S3. Supongamos que desea ejecutar una consulta SQL contra estos datos. Podría verse tentado a ejecutar un proceso para cargarlos en una base de datos relacional y luego ejecutar sus consultas SQL. Sin embargo, con AWS, en realidad no necesita hacer eso.
Hablemos de Amazon Athena.

AMAZON ATHENA: Es un gran servicio sin servidor para utilizar con sus lagos de datos porque le permite consultar datos en S3 utilizando SQL estándar, de forma similar a como lo haría con una base de datos relacional, todo ello sin necesidad de mover o cargar los datos en una base de datos. Puede consultar los datos directamente fuera de S3, lo que le permite ejecutar consultas ad hoc contra sus conjuntos de datos. Con Athena, no es necesario administrar un clúster o un almacén de datos para ejecutar sus consultas SQL.

Amazon Athena es un servicio de consulta interactivo que facilita el análisis de datos directamente en Amazon Simple Storage Service (Amazon S3) utilizando SQL estándar. Con unas pocas acciones en la consola de administración de AWS, puede apuntar Athena a sus datos almacenados en Amazon S3 y comenzar a utilizar SQL estándar para ejecutar consultas ad-hoc y obtener resultados en cuestión de segundos.

Athena se integra con AWS Glue ya que admite de forma nativa la consulta de conjuntos de datos y fuentes de datos que estén registrados en el catálogo de datos de AWS Glue. Este tipo de integraciones nativas son una de las razones por las que AWS es una gran opción para operar lagos de datos. Los diferentes servicios de AWS trabajan juntos como bloques de construcción para formar su solución.

Otro servicio de AWS que se integra directamente con S3 para la analítica es Amazon Redshift, el servicio de almacenamiento de datos. Redshift le permite girar clústeres para ejecutar consultas SQL complejas para la analítica contra sus datos.
Puede cargar datos en Redshift desde varias fuentes más allá de S3, lo que le ofrece la posibilidad de ejecutar uniones entre conjuntos de datos.

Athena y Redshift son excelentes para analizar datos que ya se han almacenado en S3.
Pero, ¿qué ocurre si desea analizar datos a medida que llegan a su lago de datos casi en tiempo real? Por ejemplo, imagine que tiene dispositivos IoT enviando actividad sísmica a

AWS para su análisis, enviando 60 puntos de datos cada segundo, y que, en última instancia, está almacenando estos datos en S3.
En este escenario, digamos que tiene decenas de miles de dispositivos ingiriendo los datos y ejecutando análisis sobre ellos, digamos en lotes, una vez cada hora con el objetivo de generar una alerta cuando los puntos de datos superen un umbral definido.
Pues bien, si quiere alertar a la gente de que puede avecinarse un terremoto, ejecutar este análisis una vez cada hora no será suficiente. Necesita una forma de detectar anomalías en tiempo real. Pues bien, como ya se habrá dado cuenta, cuando hablamos de "tiempo real", lo más probable es que estemos hablando de Amazon Kinesis, que es el caso que nos ocupa.

Puede utilizar Kinesis Data Streams o Kinesis Firehose para la ingestión de datos en tiempo real, pero también puede analizar esos datos en tiempo real utilizando Kinesis Data Analytics para hacer cosas como generar cuadros de mando en tiempo real.

KINESIS DATA ANALYTICS: Amazon Kinesis Data Analytics es la forma más sencilla de transformar y analizar datos de streaming en tiempo real con Apache Flink. Apache Flink es un marco y un motor de código abierto para el procesamiento de flujos de datos. Amazon Kinesis Data Analytics reduce la complejidad de crear, administrar e integrar aplicaciones de Apache Flink con otros servicios de AWS. Amazon Kinesis Data Analytics se encarga de todo lo necesario para ejecutar aplicaciones de streaming de forma continua y se escala automáticamente para adaptarse al volumen y el rendimiento de los datos entrantes. Con Amazon Kinesis Data Analytics, no hay servidores que administrar, no hay cuota mínima ni costo de configuración, y solo paga por los recursos que consumen sus aplicaciones de streaming.

El servicio le permite crear y ejecutar rápidamente código SQL contra fuentes de streaming para realizar análisis de series temporales, alimentar cuadros de mando en tiempo real y crear métricas en tiempo real. Puede procesar y analizar datos de flujo utilizando SQL estándar. Esto funcionaría perfectamente para nuestro ejemplo de dispositivos IoT que envían datos sísmicos, ya que podría consultar los datos a medida que llegan, y si los valores superan los umbrales normales, entonces puede enviar una alerta a través de Simple Notification Service.

Con Amazon Kinesis Data Analytics para aplicaciones SQL, puede procesar y analizar datos de streaming utilizando SQL estándar. El servicio le permite crear y ejecutar rápidamente código SQL potente contra fuentes de streaming para realizar análisis de series temporales, alimentar paneles de control en tiempo real y crear métricas en tiempo real.

Para empezar a utilizar Kinesis Data Analytics, debe crear una aplicación de análisis de datos Kinesis que lea y procese continuamente datos de flujo. El servicio admite la ingesta de

datos de fuentes de streaming de Amazon Kinesis Data Streams y Amazon Kinesis Data Firehose. A continuación, puede crear su código SQL utilizando el editor interactivo y probarlo con datos de streaming en directo. También puede configurar los destinos a los que desea que Kinesis Data Analytics envíe los resultados. Kinesis Data Analytics admite Amazon Kinesis Data Firehose (Amazon S3, Amazon Redshift, Amazon Elasticsearch Service y Splunk), AWS Lambda y Amazon Kinesis Data Streams como destinos.

La otra gran ventaja de Kinesis Analytics es que puede configurar los destinos a los que desea enviar los resultados de sus análisis.

Así que, si desea generar un panel de control en tiempo real para los datos entrantes, y luego también guardarlos en S3 o en otro lugar, como Amazon Elasticsearch Service, para las capacidades de búsqueda, todo eso es posible utilizando la familia de servicios Kinesis.

AMAZON ELASTICSEARCH SERVICE: O Amazon ES, es un motor de búsqueda y análisis de código abierto para todo tipo de datos. Esos datos pueden incluir texto, geoespaciales, estructurados o no estructurados.
Puede enviar datos en tiempo real a Amazon Elasticsearch Service, pero también admite el uso de datos de S3. Una forma común de utilizar Amazon ES es utilizarlo para análisis de registros ya que es excelente para indexar datos de registro de texto completo de varias fuentes para hacerlos consultables y descubribles.
Amazon ES se utiliza con mucha frecuencia en la pila Elasticsearch, Logstash, Kibana o ELK, que puede ofrecerle un sólido conjunto de complementos para ingerir, almacenar y visualizar datos.

La visualización es una forma estupenda de entender los datos que ha recopilado, agregado y analizado.
Kibana es una herramienta de visualización compatible a través de Amazon ES, pero AWS también ofrece Amazon QuickSight para la visualización, que veremos más adelante.

Tenga en cuenta que Amazon Elasticsearch Service (Amazon ES) tiene un sucesor llamado Amazon OpenSearch Service.

AMAZON OPENSEARCH SERVICE: Es una suite de análisis y búsqueda distribuida de código abierto derivada de Elasticsearch. Elasticsearch es un popular motor de búsqueda y análisis de código abierto para casos de uso como el análisis de registros, la monitorización de aplicaciones en tiempo real y el análisis del flujo de clics. Con OpenSearch Service, obtendrá acceso a las últimas versiones de OpenSearch Service y compatibilidad con 19 versiones de Elasticsearch (versiones 1.5 a 7.10)

La principal conclusión es que todo depende totalmente de su caso de uso. A veces puede parecer que los diferentes servicios de AWS hacen básicamente lo mismo, pero cada servicio de AWS tiene sus propias fortalezas que se adaptan a casos de uso específicos. Esas fortalezas pueden o no jugar bien con su caso de uso. Asegúrese de profundizar en cada servicio antes de decidir lo que desea utilizar para procesar y analizar los datos en su solución de lago de datos.

AWS LAKEFORMATION

Ahora que conocemos algunos de los diferentes servicios para construir y utilizar un lago de datos, pensemos en cómo podemos ponerlos todos juntos. Puede ser un proceso complicado conseguir que un lago de datos esté listo para su uso en AWS.

Podría, por supuesto, ir y aprovisionar y configurar todos estos servicios individualmente como Amazon S3 para el almacenamiento, rastreadores y clasificadores de AWS Glue para rastrear y categorizar los datos en el catálogo de datos de Glue, trabajos de AWS Glue para transformar los datos, y luego utilizar herramientas como Athena, QuickSight o EMR para el análisis y la visualización de los datos.
Eso podría llevar mucho tiempo y es posible que aún no esté preparado. Así que en lugar de recorrer y aprovisionar cada recurso individual de AWS y luego configurarlos todos para que trabajen juntos para formar su lago de datos, hablemos del servicio AWS Lake Formation.

Lake Formation automatiza muchos de los pasos manuales que suelen ser necesarios para crear lagos de datos. Estos pasos incluyen recopilar, limpiar, mover, y catalogar los datos y ponerlos a disposición de forma segura para obtener información.

El funcionamiento consiste en apuntar Lake Formation a las fuentes de datos, y luego rastrear esas fuentes y mover los datos a su nuevo lago de datos S3. A partir de ahí, Lake Formation administra los rastreadores de AWS Glue y los trabajos ETL de AWS Glue, el catálogo de datos, la configuración de seguridad y el control de acceso.
Una vez que los datos están almacenados de forma segura en el lago de datos, puede utilizar los servicios analíticos de su elección como Amazon Athena, Amazon Redshift o Amazon EMR.

Puede crear sus propios rastreadores y clasificadores personalizados para utilizarlos a través de Lake Formation, pero Lake Formation también suministra blueprints que puede utilizar. Un blueprint es una plantilla que le permite ponerse en marcha rápidamente para ingerir datos en su lago de datos. Hay varios blueprints entre los que puede elegir, cada uno para una fuente de datos predefinida, como una base de datos relacional o registros de AWS CloudTrail. Los blueprints toman la fuente de datos, el destino de los datos y la programación.

Una vez que elija un blueprint, podrá crear un flujo de trabajo.

Los flujos de trabajo consisten en rastreadores, trabajos y disparadores de AWS Glue que se generan para usted. Los flujos de trabajo se ejecutan bajo demanda o según una programación. Cuando se inicia un flujo de trabajo, puede ver el estado del mismo directamente en la consola de AWS Glue.
Si necesita fuentes de datos más personalizadas, procesos de transformación o herramientas en su lugar para su lago de datos, siempre puede construirlo manualmente usted mismo.

AWS Lake Formation puede ser una gran herramienta para utilizar para comenzar con los lagos de datos en AWS. Hace que sea más fácil poner todos los bloques de construcción juntos para una solución.
Sin embargo, tiene que entender que ***Lake Formation no es un lago de datos en sí.***
Es un servicio que le ayuda a orquestar todas las diferentes piezas y partes que componen su lago de datos, como S3 y Glue.
Una vez que necesite una mayor personalización para su lago de datos, podría optar por hacerlo todo paso a paso con cada servicio individual de AWS.

AWS Lake Formation le facilita la creación, la seguridad y la administración de lagos de datos. Lake Formation le ayuda a hacer lo siguiente, ya sea directamente o a través de otros servicios de AWS:

• Registrar los buckets y rutas de Amazon Simple Storage Service (Amazon S3) donde residirá su lago de datos.

• Orquestar flujos de datos que ingieran, limpien, transformen y organicen los datos sin procesar.

• Crear y administrar un catálogo de datos que contenga metadatos sobre las fuentes de datos y los datos del lago de datos.

•Definir políticas granulares de acceso a los metadatos y los datos mediante un modelo de concesión/revocación de permisos.

El siguiente diagrama ilustra cómo se cargan y aseguran los datos en Lake Formation:

Como muestra el diagrama, Lake Formation administra los rastreadores de AWS Glue, los trabajos ETL de AWS Glue, el catálogo de datos, la configuración de seguridad y el control de acceso. Una vez que los datos están almacenados de forma segura en el lago de datos, los usuarios pueden acceder a ellos a través de los servicios de análisis que elijan, incluidos Amazon Athena, Amazon Redshift y Amazon EMR.